

강화 학습 기반 주식 트레이딩 시스템에 대한 연구

김경훈, 김휘군, 서주연, 박상현[†]

연세대학교 컴퓨터과학과

{kkh115505, jinhuijun, sjy9728s, sanghyun}@yonsei.ac.kr

A Study of Stock Trading System based on Reinforcement Learning

Kyeonghun Kim, Jin Huijun, JuYeon Seo, Sanghyun Park[†]

Dept. of Computer Science, Yonsei University

요 약

주식 트레이딩 시스템은 주식의 변동성에 따라 포트폴리오를 구성하는 시스템을 일컫는다. 하지만 기존 연구에서 제안된 전통적인 통계적 접근법은 상승세 혹은 하락세 등 주식 시장의 특징을 반영하지 못한다. 최근 주목받고 있는 신경망을 이용한 강화 학습 기법은 복잡한 주식 시장의 특성을 파악하는 데 사용할 수 있다. 따라서 본 논문에서는 Policy Gradient, Actor-Critic을 활용한 강화 학습 기법을 적용하여 주식 트레이딩 시스템을 구축하고자 한다. DMI 지표를 이용하여 주식 시장을 하락형, 횡보형, 상승형으로 분류한 후, 각 패턴에서 효율적인 시스템을 구축한다. 실험을 통해 패턴별 특징을 분석하여 제안하는 강화 학습 기반 주식 트레이딩 시스템의 높은 수익률 및 신뢰성 향상을 입증하였다.

1. 서 론

투자자와 금융 분석가들은 주식 트레이딩을 실천하는 스마트 모델 구축에 항상 많은 관심을 가지고 있고 이에 따라 많은 연구가 현재까지 진행되어왔다. 그럼에도 불구하고, 매수와 매도에 대한 최적의 타이밍을 찾는 문제는 주가에 영향을 주는 요소들이 많기 때문에 해결하기 어려웠다.[1]

주식은 다양한 변수에 의해 결정되기 때문에 비정상성(Non-stationarity)과 비선형성(Non-linearity)의 특징을 가지고 있다. 따라서 전통적인 통계 모델과 같은 기존 분석 방법론들은 이러한 비정상성과 비선형성을 반영하지 못하기 때문에 주식 트레이딩 문제에서 좋지 못한 모습을 보였다. SVM으로 적용했을 때 좋은 수익율을 기록하거나, 전혀 그렇지 못한 결과를 보였고,[2] Decision-Tree의 경우에도 상승세와 하락세인 주식의 패턴을 잘 잡아내지 못했다.[3] 딥 러닝은 다양한 분야에서 활용되어 좋은 결과를 보이고 있다. 또한, 주식이 가지고 있는 특징도 잘 잡아내기 때문에 주식 트레이딩에 활용한 결과가 좋았다. [4] 최근 연구에서 강화 학습(Reinforcement Learning)을 기반으로 주식 트레이딩을 하는 연구가 많이 진행되었으며, 좋은 결과를 보였기 때문에 본 논문에서는 강화 학습으로 주식 트레이딩 문제를 접근해본다.

주식을 분석할 때 가장 자주 사용되는 것은 주식의 추세이며, 이와 관련된 많은 지표가 존재해 주식의 패턴을 찾아내려는 연구가 많이 진행되었다. 그리고 주식의 패턴 정보를 주식 트레이딩에 사용하는 경우에 더 좋은 수익률과 정확도를 얻을 수 있다.[5]

이번 논문에서는 주식에 다양한 추세가 있지만 크게 하락형, 횡보형, 상승형의 형태를 띄고 있는 종목을 각각 하나씩 선정하였다. 그리고 각 종목에 대해 Policy Gradient와 Actor-Critic 모델을 적용해 결과를 분석해본다.

2. 관련연구

강화학습은 정의되어 있는 상태 상에서 에이전트가 환경과의 상호작용을 하면서 최적의 행동을 배우는 학습법이다. 행동에 따른 보상을 부여해 더 좋은 행동을 하도록 하며, 이번 논문에서는 Policy Gradient 기법과 Actor Critic 기법을 사용한다.

2.1 Policy Gradient (PG)

Policy Gradient는 널리 사용되는 강화 학습 알고리즘이다. 이 알고리즘은 θ 에 대해 목적함수를 미분한 $\nabla_{\theta} J(\pi_{\theta})$ 방향으로 파라미터 θ 를 조절한다.

$$\begin{aligned}\nabla_{\theta} J(\pi_{\theta}) &= \int_S \rho^{\pi}(s) \int_A \nabla_{\theta} \pi_{\theta}(a|s) Q^{\pi}(s, a) da ds \\ &= \mathbb{E}_{s \sim \rho^{\pi}, a \sim \pi_{\theta}} [\nabla_{\theta} \log \pi_{\theta}(a|s) Q^{\pi}(s, a)]\end{aligned}$$

State 분포 $\rho^{\pi}(s)$ 는 Policy의 파라미터에 의존하지만, Policy Gradient는 State 분포의 경사에 의존하지 않는다.

이 방법론은 이것은 Performance Gradient의 계산을 간단한 Expectation으로 감소시켰기 때문에 중요한 가치를 가지고 있다. 이 알고리즘이 해결해야 하는 문제로 Action-value

* 이 논문은 2020년도 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의 지원(IITP-2017-0-00477, SW컴퓨팅산업원천기술개발사업(SW스타랩)), 국토교통부의 스마트시티 혁신인재육성사업으로 지원되었습니다.

[†] 교신 저자: sanghyun@yonsei.ac.kr

function $Q^\pi(s, a)$ 를 추정하는 것이 있지만, Sample Return r 을 사용하여 $Q^\pi(s_t, a_t)$ 와 같이 값을 추정함으로써 해결한다.[6]

2.2 Actor-Critic (AC)

PG에서 두 가지 핵심 요소는 Policy와 Action-value-function이다. Policy Gradient에서는 Policy만 학습을 했지만, Value-function을 학습한다면 더 좋은 policy를 얻을 수 있고, 이를 수행한 알고리즘이 Actor-Critic이다.

Actor-Critic은 Actor와 Critic 두 가지 모델로 구성되어 있다. 알고리즘에서 사용되는 Action-value-function을 $Q_w(a|s)$ 라 할 때, Critic은 파라미터 w 를 업데이트한다. 또한, 현재의 Policy를 $\pi_\theta(a|s)$ 라 할 때, Actor는 Critic이 제안한 방향으로 Policy를 결정할 파라미터 θ 를 업데이트한다. 즉, Critic은 Q-function을, Actor는 Policy를 추정한다고 할 수 있다.[7]

2.3 DMI

상승 추세라면 당일 고가는 전일 고가보다 높을 것이고 하락 추세라면 당일 저가는 전일 저가보다 낮을 것이다. 이 추세를 알기 위해서 다음과 같은 공식을 통하여 고가의 비교와 저가의 비교를 통해서 +DM과 -DM값을 구한다.

$$\begin{aligned} +DM &= \text{당일 고가} - \text{전일 고가} \\ -DM &= \text{전일 저가} - \text{당일 저가} \end{aligned}$$

그리고 어느 정도의 가격 변동이 있었는가를 알기 위해 다음 3가지 경우 중 가격의 변동이 가장 큰 것을 선택하는 것이 TR(True Range)다.

$$TR = \max(\text{당일고가} - \text{당일저가}, \text{당일고가} - \text{전일종가}, \text{당일저가} - \text{전일종가})$$

+DI는 가격변동 내에서 상승의 추세가 지속될 수 있는가를 측정하는 선을 의미하고, -DI는 가격변동 내에서 하락의 추세가 지속될 수 있는 선을 의미하게 된다. 이동평균은 주로 6일 혹은 14일의 이동평균을 사용한다.

$$+DI = \frac{+DM \text{의 이동평균}}{TR \text{의 이동평균}}, -DI = \frac{-DM \text{의 이동평균}}{TR \text{의 이동평균}}$$

+DI선, -DI선을 그었을 때, +DI선이 -DI선보다 위에 존재하면 상승추세, -DI선이 +DI선보다 위에 존재하면 하락 추세를 의미한다.

2.4 Portfolio Value (PV)

PV는 현재 자신이 보유하고 있는 주식을 모두 매도했을 때 얻을 수 있는 현금 보유량을 의미한다. 이 값이 초기값보다 커진다면 이익을 본다고 해석한다.

$$PV = \text{주식 보유 수} \times \text{당일 주가} + \text{현금 잔고}$$

표1. 모델 구성

구성	내용
환경	주식 데이터
Agent	Policy Gradient 모델, Actor-Critic 모델
상태	주식관련지표, Agent
행동	산다, 판다, 보류한다.
보상	임계점보다 이익이나 손해
Policy	행동을 수행하는 Network
Critic	Actor를 평가하는 Network

3. 모 델

본 논문에서 사용하는 강화학습 모델은 표1과 같이 정의한다.

상태(State)는 주식의 시가, 고가, 종가, 저가 그리고 거래량 데이터를 통해서 추세를 알 수 있는 비율 지표 11개와 에이전트의 상태를 알 수 있는 주식 보유 비율, 포트폴리오 가치 비율 2가지를 더해 총 13개의 상태를 사용했다.

Agent가 수행하는 행동(Action)은 산다(BUY), 판다(SELL), 보류한다(HOLD)가 있다.

보상은 모델의 모든 행동에 부여하는 것이 아니라 일정 수익(손해)이 나면 보상을 준다. 설정한 임계점의 수익을 넘으면 상승한 포트폴리오 비율만큼 주었으며, 손해를 보면 하락한 포트폴리오 비율만큼 보상을 부여했다.

PG의 Network는 LSTM을 3 layer로 쌓아서 구성하였고, 마지막 layer는 Action을 출력하기 위한 output 차원이 행동의 개수인 Dense layer를 사용했다. 최종적으로 softmax 함수를 사용해서 행동을 수행할 확률로 만들었다. 학습 속도(Learning-rate)는 0.0001로 하였다.

AC의 Network는 Actor Network와 Critic Network가 각각 존재한다. Actor의 경우에는 Policy Gradient의 Policy와 동일하게 구성하였다. Critic은 LSTM 1개와 output 차원이 1인 Dense layer를 사용했다. 최종적으로 Value-function 값을 얻어야 하므로 linear 함수를 사용했다. 학습 속도는 0.00001로 하였다.

PG와 AC의 Optimizer는 모두 Adam이고, Dropout은 0.5를 사용했다.

4. 실험 결과

두 강화학습 모델을 훈련하기 위해 DMI 지표를 활용해서 LG전자(하락형), 팬오션(횡보형) 그리고 삼성 바이오로직스(상승형)로 주식 세 종목을 선정했다. Train 기간은 2017년 1월부터 2018년 12월까지 2년으로, Test기간은 2019년 1년으로 설정했다. 학습을 진행할 보상 임계점 값을 0.02(2%), 0.05(5%), 0.1(10%)로 설정하여 실험을 진행하였다.

하락형인 LG전자(그림1의 (상))의 실험 결과(표2 (상))를 보면, 전반적으로 PG가 AC보다 더 좋은 성능을 보인다. PG는 Monte-Carlo 특성을 가지고 있어서 하락세인 주가 중에서도 수익을 낼 수 있는 구간을 찾을 수 있지만, AC의 같은 경우에




그림 1. (상)LG전자, (중)팬오션, (하)삼성바이오로직스
2017년 1월~ 2018년 12월까지의 주가

는 TD(Time Difference) 특성을 가지고 있기 때문에 주로 부정 보상으로 update를 해서 수익점을 잡아내지 못했다.

횡보형인 팬오션(그림 1의 (중))의 실험 결과(표 2 (중))를 보면 PG와 AC 둘 다 좋지 못한 성능을 보이는 것을 알 수 있다.

긍정과 부정 보상이 계속 교차로 나오면서 정책이 잘 수렴하지 못했다.

상승형인 삼성바이오로직스(그림 1의 (하))의 실험 결과 (표 2 (하))를 보면 PG와 AC 둘 다 수익률이 높게 나온 것으로 보아, 강화학습의 알고리즘이 상승형일 때 좋은 정책을 만드는 것으로 해석된다.

5. 결 론

본 논문에서는 최근 주식 트레이딩 문제에서 좋은 성능을 보이고 있는 강화학습의 두 알고리즘 PG와 AC를 주식의 각 패턴별로 각각 적용해보았다.

두 강화학습 알고리즘은 주식이 하락세 또는 상승세를 계속 해서 보이는 것과 같이 일정한 추세를 보이는 경우에 더 좋은 수익률을 기록했다. 이 때 하락세인 경우에는 PG가, 상승세인 경우에는 AC가 더 좋은 수익률을 얻었다. 이는 각 두 알고리즘의 특징으로 인해 발생한 결과라고 해석한다.

연구의 한계점으로는 횡보형인 경우 좋은 수익률을 얻지 못했으며, 이를 위한 추가적인 대안이 필요할 것으로 보인다. 추후 연구로, 주가는 외부 변수에 의해 결정되는 경우가 많기 때문에 외부 정보를 반영할 수 있는 연구가 필요할 것이다.

또한 이러한 다양한 외부 정보를 반영할 수 있는 연구가 진행된다면 다양한 외부 변수를 고려해야 하는 스마트 시티 관련 연구에도 적용할 수 있을 것으로 보인다.

표 2. LG전자(상), 팬오션(중), 삼성바이오로직스(하) 실험 결과

보상임계점	Policy Gradient	Actor-Critic
0.02	+8.17%	+0.48%
0.05	+1.36%	+4.48%
0.1	+11.6%	-5.59%

보상임계점	Policy Gradient	Actor-Critic
0.02	+0.023%	-0.163%
0.05	-0.444%	+1.05%
0.1	-0.617	+0.86%

보상임계점	Policy Gradient	Actor-Critic
0.02	+33.3%	+4.7%
0.05	-10.6%	+23.35%
0.1	+7.15%	+13.95%

참고문헌

- [1] Jae Won Lee, Jonghun Park, Jangmin O, Jongwoo Lee, and Euysseok Hong. A multiagent approach to q-learning for daily stock trading. Systems, Man and Cybernetics, Part A: Systems and Humans, IEEE Transactions on, 37(6):864-877, Nov. 2007
- [2] A. Fan, M. Palaniswami, Stock selection using support vector machines, in: Proceedings of the International Joint Conference on Neural Networks, pp. 1793-1798, 2001
- [3] S.D. Kim, J.W. Lee, J. Lee, J. -S. Chae, A two-phase stock trading system using distributional differences, in Proceedings of the International Conference on Database and Expert Systems Applications, pp. 143-152, 2002
- [4] Yong B.X., Abdul Rahim M.R., Abdullah A.S., A Stock Market Trading System Using Deep Neural Network. AsiaSim 2017: Modeling, Design and Simulation of Systems, 356-364, August 2017
- [5] Roberto Cervello-Royo, Francisco Guijarro, Karolina Michniuk, Stock market trading rule based on pattern recognition and technical analysis: Forecasting the DJIA index with intraday data, Expert Systems with Applications 42(14), 5963-5975, August 2015
- [6] Silver, David, Lever, Guy, Heess, Nicolas, Degris, Thomas, Wierstra, Daan, and Riedmiller, Martin. Deterministic policy gradient algorithms. ICML, 1-387-1-395, 2014
- [7] Vijaymohan Konda, John N. Tsitsiklis Actor-critic Algorithms. In Advances in neural information processing systems, pp 1008-1014, 2000