



저작자표시-비영리-변경금지 2.0 대한민국

이용자는 아래의 조건을 따르는 경우에 한하여 자유롭게

- 이 저작물을 복제, 배포, 전송, 전시, 공연 및 방송할 수 있습니다.

다음과 같은 조건을 따라야 합니다:



저작자표시. 귀하는 원저작자를 표시하여야 합니다.



비영리. 귀하는 이 저작물을 영리 목적으로 이용할 수 없습니다.



변경금지. 귀하는 이 저작물을 개작, 변형 또는 가공할 수 없습니다.

- 귀하는, 이 저작물의 재이용이나 배포의 경우, 이 저작물에 적용된 이용허락조건을 명확하게 나타내어야 합니다.
- 저작권자로부터 별도의 허가를 받으면 이러한 조건들은 적용되지 않습니다.

저작권법에 따른 이용자의 권리는 위의 내용에 의하여 영향을 받지 않습니다.

이것은 [이용허락규약\(Legal Code\)](#)을 이해하기 쉽게 요약한 것입니다.

[Disclaimer](#)

금융공학 석사학위 논문

실제 시장상황을 고려한
강화학습 기반의
자동화 트레이딩

아주대학교 대학원

금융공학과

정 계 은

실제 시장상황을 고려한 강화학습 기반의 자동화 트레이딩

지도교수 김 하 영

이 논문을 금융공학 석사학위 논문으로 제출함.

2019 년 2 월

아 주 대 학 교 대 학 원

금 융 공 학 과

정 계 은

정계은의 금융공학 석사학위 논문을 인준함.

심사위원장 김하영 인

심사위원 구형건 인

심사위원 심규철 인

아 주 대 학 교 대 학 원

2018년 12월 24일

1973

UNIVERSITY

논문요약

본 연구는 강화 학습으로 자동 트레이딩 시스템을 구축할 때 생기는 문제를 해결하기 위해 금융 데이터의 한계를 극복하고 실제 금융 시장 상황을 반영하는 세 가지 방법을 제안하여 총 이익을 극대화하는 것을 목표로 하고 있다. 첫째, 주식을 어떻게 거래할지 결정을 내리는 동시에 거래할 주식의 수를 예측하여 정하는 거래 시스템을 제안한다. 강화학습 방법의 일종인 Deep Q-Network(DQN)에 Deep Neural Network(DNN) Regressor를 추가하여 주식 수를 예측하는 자동화 시스템을 설계한다. 둘째, 혼란스러운 시장에서 어떤 전략이 이익을 내는데 효과적인지 분석하기 위해 Q-value를 사용하여 다양한 행동 전략을 연구한다. 마지막으로, 전이학습을 제안하여 충분하지 않은 금융 데이터로 인한 과적합을 방지한다. 본 연구에서는 이 세 가지 방법을 S&P500, KOSPI, HSI, EuroStoxx50 등 4가지 주식 지수를 사용하여 실험적으로 검증한 후 광범위한 연구를 수행한다. DNN Regressor로 주식 수를 정하는 자동 거래 시스템은 S&P500에서 4배, KOSPI에서 5배, HSI에서 12배, EuroStoxx50에서 6배의 수익이 증가하는 효과를 보였다. 시장 상황이 혼란스러운 상황에서 거래 결정을 미루는 전략은 S&P500에서 18%, KOSPI에서 24%, EuroStoxx50에서 49%의 순이익 증가율을 보였다. 또한 전이학습은 총 이익을 S&P500 2배, KOSPI 3배, HSI 2배, EuroStoxx50 2.5배 증가시킨다. 세 가지 제안된 방법을 모두 사용하는 거래 시스템은 S&P500에서 13배, KOSPI에서 24배, HSI에서

30배, EuroStoxx50에서 18배의 총 수익을 창출 해 시장 및 기존 강화학습 모델을 능가한다.

키워드: Reinforcement learning; Deep Q-learning; Stock trading; Trading strategy; Transfer learning



차례

논문요약	i
차례	iii
그림 차례	v
표 차례	vi
1. 서론	1
2. 관련 연구	7
3. 이론적 배경: Q-learning을 기반으로 한 트레이딩	10
4. 제안방법	14
4.1 거래할 주식 수 정하기	14
4.1.1 Q-value를 이용한 주식 수 결정	15
4.1.2 행동 의존적인 DNN regressor로 주식 수 결정	18
4.1.3 행동 독립적인 DNN regressor로 주식 수 결정	21
4.2 혼란스러운 시장에서의 행동 전략	22
4.3 인덱스 구성 주식을 이용한 이전 학습	24
5. 실험 결과 및 비교	30
5.1 인덱스와 관련된 구성 주식을 사용한 이전 학습.	35
5.2 매매할 주식 개수 정하기	40
5.3 혼란스러운 시장에서의 행동 전략	44

6. 결론	47
참고문헌	50
Abstract	58



그림 차례

그림 1. 신경망에 의해 업데이트되는 Deep Q-learning	12
그림 2. 행동 의존적인 DNN regressor로 주식 수 결정	17
그림 3. NumDReg – AD 방법의 구조	19
그림 4. NumDReg – AD with three – step training의 훈련과정 순서도 . . .	20
그림 5. NumDReg – ID with three – step training의 훈련과정 순서도 . . .	22
그림 6. 이전학습의 학습 과정	28
그림 7. 네 가지 인덱스의 움직임	31
그림 8. S&P500과 그 구성 주식들 간의 관계와 측정방법에 따른 이전 학습 결과 비교	40
그림 9. S&P500을 사용한 NQ와 NDA 모델, 그리고 이전 학습을 적용한 결과의 비교	43
그림 10. S&P500을 사용한 NENDA, NENDA3, NENDI3 모델의 비교	44
그림 11. S&P500를 사용한 행동 전략의 비교	45

표 차례

표 1. 데이터 종류	32
표 2. 모델 약어	34
표 3. 상관관계와 신경망 복원오차에 따라 선택된 주식 종목	36
표 4. 사전훈련 모델들의 결과	39
표 5. NQ, NDA, NDI로 매매 개수를 정하며 거래하고 이전 학습과 단계별 학습을 적용한 결과	43
표 6. NENDI3에 행동 전략을 적용한 결과	45

1. 서론

주식 트레이딩 문제는 중요하지만 금융 시장의 수많은 부분을 고려해야 하기에 복잡하고 어려운 문제이다. (Brock, Lakonishok, & LeBaron, 1992; Dymova, Sevastianov, & Bartosiewicz, 2010; Kuo, Chen, & Hwang, 2001; Lin, Yang, & Song, 2011; Press, 2016). 또한 변동성이 크고 noise가 많기 때문에 금융 데이터를 분석하기가 어렵고 이때문에 실제 시장의 주식 거래자는 복잡한 시장 상황에 자주 혼동된다. 하지만 금융적 문제를 모델링하는 것은 고도의 비선형 관계를 추정하기 때문에 전통적인 알고리즘을 사용하기 어렵다. (Ang & Quek, 2006, Chavarnakul & Enke, 2008, Chen, Firth, & Rui, 2001, Oh & Kim, 2002).

주식 트레이딩의 핵심 요소는 거래 전략의 확인(Brock et al., 1992; Fama, 1995, Levich & Thomas, 1993)과 거래할 주식수 결정(Black & Scholes, 1973; Mastinšek, 2006)이다. 주식 트레이딩에 대한 초기 연구들은 거래 규칙을 찾는 데 중점을 두었다. 예를 들어, Brock, Lakonishok와 LeBaron(1992)은 1897년에서 1986년까지 다우 존스 지수를 사용하여 이동 평균과 거래 범위 breakout 규칙을 테스트했다. 연구 결과에 따르면 매수 신호가 매도 신호보다 일관되게 높은 수익률을 나타내며 변동성을 덜 보인다. Levich와 Thomas(1991)는 외환 선물에 대한 통계검정을 사용하여 이동 평균과 간단한 기술적 트레이딩 규칙의 수익성을 연구했다. 그 결과, 간단한 기술적 트레이딩

규칙이 수익성이 있고 새로운 통계검정 방법에 따라 이 규칙은 부트스트랩(bootstrap) 방법을 사용한 경험적 분포함수보다 더 유의하는 것을 보여줬다. Fama(1995)는 주식 가격의 랜덤 워크에 대해 논의하고 펀더멘털 매수-유지 전략이 효율적인지 분석했다.

이와 동시에 많은 연구에서 가격과 거래량 간의 관계에 초점을 맞추거나 거래할 최적의 주식 수를 찾는 데 집중했다 (Black & Scholes, 1973; Campbell, Grossman, & Wang, 2011, Hess, Epps, & Bamber, 2013, Mastinšek, 2006). 실제 시장의 거래자들은 매번 일정량의 주식을 거래하지 않으므로 수익은 주식의 개수에 직접적으로 영향을 받는다. 따라서 일반적으로 거래자들은 최적의 주식 거래 개수를 할당하여 파생 상품으로 포트폴리오를 최적화하고 헤지하는 전략을 세우길 원한다.

많은 연구에서 최적의 거래 전략을 식별하기 위해 자동화된 거래 시스템 (또는 알고리즘 트레이딩, algorithmic trading [AT])을 연구한다 (Brownlees, Cipollini, & Gallo, 2011, Chaboud, Chiquoine, Hjalmarsson, & Vega, 2009, Hendershott & Riordan, 2011, Scholtus, Van Dijk, & Frijns, 2014). AT는 거래자가 유동성을 개선하고 이익을 향상시키는 데 사용할 수 있는 사전 프로그래밍 된 모델을 기반으로 한다 (Hendershott, Jones, & Menkveld, 2011). Hendershott와 Riordan (2011)은 AT가 유동성 및 펀더멘털 가치와의 가격 편차 측면에서 시장에 기여하고 있음을 지적하면서 AT와 그 역할을 조사했다. Chaboud, Chiquoine, Hjalmarsson, Vega (2014)는 외환 시장에서 AT의 영향을 연구하여 AT가 가격

발견의 속도를 높이고 고빈도 수익의 자기 상관 관계를 향상시키는 것을 발견했다.

그러나 AT는 금융 시장이 매우 복잡하기 때문에 모든 매매 순간에 수익을 내는 결정을 하기에 불충분하다 (Domowitz & Yegerman, 2006; Hu et al., 2015; Yadav, 2015). Hu 등 (2015)은 AT의 한계점으로 AT가 향후 시장 추세를 예측하는 데 어려움이 있다는 점을 지적했다. 시장에 오랜 기간 지속적인 상승 추세가 존재할 때 AT가 시장 대비 결과가 좋지 어려웠다. 이러한 한계를 극복하기 위해 강화학습에 기반한 주식 트레이딩에 대한 많은 시도가 있어왔다.

강화 학습은 순차적 결정을 가능하게 하고 정답이 없는 데이터를 학습할 수 있는 기술이다. Moody와 Saffell (2001)은 직접 강화학습(direct reinforcement learning)을 사용하여 포트폴리오와 거래할 주식을 최적화했다. 그들은 투자 의사 결정과 같은 확률적 통제 문제(stochastic control problems)를 해결하기 위해 회귀 강화학습(recurrent reinforcement learning)을 사용했다. Lee, Lee and Zhang (2006)은 강화학습에 메타 정책, 즉 주식을 선택하고 거래를 최적화하는 자산 배분 전략을 적용했다. Gorse (2011)는 회귀 강화학습을 사용하여 인덱스 트레이딩을 시도했다. 저자는 매일, 매주, 매월과 같은 다양한 시간 간격으로 구성된 주식 인덱스 데이터를 사용하고 그 결과를 유전 프로그래밍(genetic programming)과 비교했다. 목표는 다윈의 진화론에 기초한 유전

알고리즘(genetic algorithm)을 사용하여 적절한 해법을 찾는 것이다.

그러나 강화학습을 적용할 때 몇 가지 문제점들이 있는데 거래할 때마다 거래할 주식 개수를 결정해야 하는 점, 시장이 혼란스러울 때 매매 결정이 어려운 점, 그리고 금융 데이터의 양이 적고 변동성이 크다는 점이다. 이 논문에서, 우리의 목표는 앞서 언급한 문제들을 극복함으로써 트레이더의 총 이익을 극대화하는 것이다. 이에 따라 우리는 강화학습 거래 시스템을 개선할 세 가지 새로운 방법을 제안한다 - 거래할 주식 수 정하기, 혼란스러운 시장을 위한 행동 전략 및 이전 학습.

첫째, 우리는 주식 개수를 정하는 DNN regressor가 결합된 강화학습 거래 시스템을 제안한다. 이 네트워크 훈련은 학습 범위를 줄이고 효율적으로 개수를 정하기 위해 단계적으로 훈련된다.

둘째, 시장의 불확실성을 거래 행위의 견고성으로 측정하여 새롭게 제안된 행동 전략(action strategies)에 적용한다. 행동 전략은 훈련 전에 복잡한 금융 상황에 대비해 하나의 행동을 결정해 둔다. 사고파는 행동의 가치 차이를 이용하여 시장 상황을 측정하고 그 값이 사전에 결정된 임계 값보다 작으면 훈련된 결과 대신 미리 결정된 행동을 사용한다. 이를 통해 불확실한 금융 시장에서 적절한 조치를 취하고 알고리즘이 불확실성을 피할 수 있게 된다. 우리는 다양한 행동 전략을 경험적으로 비교한 후 혼란스러운 시장에서 최고의 전략은 주식 매매 결정을 연기하는 것임을 확인했다. 행동 전략은 또한 전략의

행동과 한계점을 조정함으로써 투자자의 성향을 반영할 수 있다.

마지막으로 양이 적고 변동이 심한 금융 데이터로 인한 과도한 문제를 처리하기 위해 이전학습(transfer learning)을 제안한다. 이 방법은 데이터 부족 문제를 해결하고 데이터의 특성 자체를 사용하여 과적합을 방지한다. 효과를 확인하기 위해 S&P500, KOSPI, HSI, EUROSTOXX50 등의 네 가지 인덱스를 선택해 실험적으로 검증했다. 실험은 상관 관계와 신경망의 복원 오차에 따라 6가지 그룹으로 나뉘어 진행됐고 각 그룹은 인덱스와 다양한 관계가 있는 인덱스 구성 주식의 부분 집합으로 구성된다.

본 연구에서 제안하는 자동화 거래 시스템은 DNN과 강화학습을 결합한 DQN (deep Q-network) 알고리즘을 기반으로 한다. DQN은 비선형 관계를 발견하고 복잡한 모델을 근사 할 수 있는 DNN (Mnih et al., 2013; Mnih et al., 2015)을 통해 강화학습을 최적화한다. 심층 신경망 학습과 같은 데이터 기반 학습 방식은 알려지지 않은 거래 규칙을 찾을 수 있다. 이익은 단일 기간 (일일)에 걸친 수정된 수익을 사용하여 계산되며, 모델은 전체 이익, 즉 전체 테스트 기간 동안의 이익 합계로 평가된다.

본 논문의 구성은 다음과 같다. 2장에서는 Q-learning을 사용하여 주식을 거래하는 방법을 설명한다. 3 장에서는 본 연구에서 제안한 3 가지 방법을 소개한다. 각 방법은 거래할 주식 수를 결정하고, 혼란스러운 경우에 대한 행동 전략을 제시하며, 상관관계와 심층 신경망을 사용하여 이전학습을 하는 것이다.

세 가지 방법의 결과는 4장에 제시되어 있다. 5장에서는 결론을 제시한다.



2. 관련 연구

강화학습으로 주식을 거래할 때는 몇 가지 어려움이 있다. 첫째, 주식 수를 결정하며 거래하는 것은 고정된 수의 주식을 거래하는 것보다 어렵다. 강화학습 시스템을 실제 시장에 적용하기 위해서는 몇 개의 주식을 사거나 팔아야 하는지 매번 결정해야 한다. 모든 거래 포지션에서 같은 양의 주식을 거래하는 것은 실제 시장 상황에 맞지 않고 주식 개수가 이익에 직접적인 영향을 미치기 때문에 거래할 주식수를 정하는 것은 금융 시장에서 중요한 쟁점이다. 또한 시장 상황에 따라 개수를 변경하면 이익을 늘릴 수 있다. 그러나 이와 같은 문제를 다루는 강화학습 연구는 거의 없다. 강화학습을 기반으로 한 대부분의 연구는 일반적으로 거래 전략을 찾는 데에만 집중한다. 주식 개수는 일반적으로 하나 또는 고정된 개수로 설정되거나 포트폴리오의 가중치로 간주된다 (Nevmyvaka, Feng, & Kearns, 2006; O et al., 2006).

둘째, 금융 시장의 방향과 상황이 항상 명확하게 구분되는 것은 아니다. 금융 시장은 명확하게 표현될 수 없을 때가 종종 있는데, 특히 금융 시장이 혼란스러운 상황에서 실제 트레이더들과 마찬가지로 강화학습 모델이 적절한 의사 결정을 내리기 어려운 상황에 직면한다. 이 경우 금융 상황의 특징을 더 잘 표현하거나, 조금이라도 적절한 행동을 선택하거나, 명확한 행동을 선택할

필요가 있다. 일부 학자는 퍼지 알고리즘(fuzzy algorithm)과 같은 다양한 알고리즘을 강화학습에 적용하여 데이터에서 더 나은 특징을 추출했다 (Kuo 외, 2001; Tan, Quek, & Cheng, 2011). Tan et al. (2011)는 강화 학습에 적응 네트워크 퍼지 추론 시스템(adaptive network fuzzy inference system)을 적용했다. 이 추가 모델은 금융 시장의 동향과 주식 이동을 동적으로 식별할 수 있다. Almahdi와 Yang (2017)의 연구는 금융 시장 모델의 경제적 요인을 포함시켰다. 그들은 구매 및 판매 신호를 확인하기 위해 Calmar Ratio를 회귀 강화학습에 적용할 것을 제안했다. 또한 강화학습을 자산 배분과 포트폴리오 재조정에도 사용하여 벤치마크한 헤지 펀드보다 우수한 결과를 보였다.

마지막으로 금융 데이터는 딥 러닝(deep learning)에 적용하기에는 소량의 데이터이다. 딥 러닝에서는 학습할 매개 변수보다 적은 데이터가 있을 때 과적합이 발생한다. 금융 데이터 또한 매우 변동성이 크며 예측할 수 없는 noise를 포함하므로 패턴이 불분명합니다. 이러한 특성으로 인해 훈련할 때 과적합이 잘 발생하며 네트워크는 극솟값으로 수렴하는 경향이 있다. 이 문제를 해결하기 위해 일부 연구에서는 소량의 데이터를 다양한 알고리즘으로 분석하여 다양한 특징을 추출했다. Dempster, Payne, Romahi, Thompson (2001)은 외환 트레이딩의 강화학습을 다루어 그 방법을 유전 프로그래밍과 비교했다. 후속 연구에서 Dempster와 Leemans (2006)는 네트워크를 리스크 관측과 동적 최적화 층으로 분리하여 외환 거래에 강화 학습을 적용했다. Deng,

Bao, Kong, Ren 및 Dai (2017)는 적극적인 의사 결정을 위해 시장 상황을 다루는 심층 학습 부분과 강화 학습 부분을 분리하였다.



3. 이론적 배경: Q-learning을 기반으로 한 트레이딩

강화 학습은 에이전트가 환경과 상호 작용할 때 누적 보상 신호를 최대화하는 학습입니다. 그림 1의 왼쪽 그림과 같이, Markov Decision Process(MDP)에 의해 정의된 환경에서 에이전트는 주어진 상태를 사용하여 동작을 선택한다 (Kaelbling, Littman, & Moore, 1996, Sutton & Barto, 1998). MDP에 따르면 환경에 해당하는 에이전트는 보상을 최대화하기 위한 조치를 선택합니다 (Bellman, 1957). 우리는 이 과정을 수학 공식을 통해 더 설명합니다. 이 과정은 (S, A, P, R, γ) 로 구성되며, S 는 상태 $\{s_1, s_2, \dots\}$ 의 집합이고, A 는 행동 $\{a_1, a_2, \dots\}$ 의 집합이며, P 는 s 가 시간 t 에서의 상태이고 a 가 시간 t 에서의 행동일 때 시간 $t+1$ 일 때 상태 s' 이 될 확률이다. R 은 보상 집합 $\{r_1, r_2, \dots\}$ 이고, γ 는 할인 계수이다. 시간 $t+1$ 에서의 보상은 시간 t 에서의 행동에 달려있다; 또한, 다음 상태는 행동에 의해 결정된다. 행동의 가치는 미래 보상의 할인된 합계로 간주될 수 있다. 따라서 정책 π 에 따라 상태 s 에서 행동 a 를 선택하면 행동의 가치는

$$Q_{\pi}(s, a) = \mathbb{E}_{\pi}[\sum_{k=0}^{\infty} \gamma^k r_{t+k+1} | s_t = s, a_t = a]. \quad (1)$$

이 행동의 가치를 Q-value라고 한다. 시간 t 에서의 상태 s_t 가 s 이고 행동 a_t 가 a 일 때, 최적 Q-value(optimal Q-value) $Q^*(s, a)$ 는 Q-value를 극대화하는 최적의

정책에 따라 결정되고 수식 (2)와 같이 나타내어 진다.

$$Q^*(s, a) = \max_{\pi} Q_{\pi}(s, a). \quad (2)$$

이 값은 수식 (3)과 같이 벨만방정식(Bellman equation)으로 표현될 수 있다.

$$Q^*(s, a) = \max_a [r_t + \gamma Q(s_{t+1}, a')]. \quad (3)$$

Q-learning (Watkins & Dayan, 1992)은 누적 보상을 최대화하기 위해 Q-value를 업데이트하는 강화학습 방법 중 하나이다. 결정론적 정책(deterministic policy)이 없으면 알고리즘은 가장 큰 Q-value을 갖는 동작을 선택한다. Q-value은 계속해서 업데이트되어 최상의 행동을 찾는 최적의 Q-value으로 수렴된다. θ 를 학습계수라 할 때 Q-value을 업데이트하는 과정은 다음과 같다.

$$Q(s_t, a_t) := Q(s_t, a_t) + \theta * \{r_t + \gamma Q(s_{t+1}, a') - Q(s_t, a_t)\}, \quad (4)$$

금융 거래는 결정론적 정책으로 일반화하기 어렵기 때문에 주식 트레이딩에 대한 많은 연구에서 Q-learning이 사용되어왔다 (Yang et al., 2012). 무작위성 뿐만 아니라 많은 변수가 금융 환경에 존재한다. 그러므로 본 연구는 2013년에 Mnih 등이 소개한 DQN을 사용한다. DQN은 신경망으로 Q-value을 업데이트하고 데이터의 비선형 성을 효과적으로 나타낸다 (그림 1 참조). 신경망은 완전하게 연결된 계층(fully connected layer)들로 구성된다. 금융

데이터가 그 자체로 매우 random하기 때문에 기존의 DQN과 달리 Q-value를 업데이트할 때 experience replay 기법을 사용하지 않는다.




그림 1. 신경망에 의해 업데이트되는 Deep Q-learning

본 연구에서 S 는 $S = \{s_1, s_2, \dots, s_T\}$ 로 표현되는 유한 집합이고 p_t 는 t 의 거래 마감 가격을, 각 상태 s_t 는 $t-199$ 에서 t 까지의 $p_t - p_{t-1}$ 을 나타낸다. A 는 $A = \{1, 0, -1\}$ 로 표현되는 유한 행동 집합이다. 행동 집합에서 1은 BUY를 나타내고 0은 HOLD를 나타내며 -1은 SELL을 나타낸다. 각 단계에서 가장 큰 Q-value를 가진 행동이 선택된다. 보상 함수는 Wang et al. (2017)에서 소개된 함수이며, $t-n$ 시점의 가격을 반영하여 t 시점의 수익율을 계산한다. 함수는 수식 (5)에서 제공되며, 여기서 p_t 는 t 시점의 거래 마감 가격이고 a_t 는 t 시점의 행동이다.

$$r_t = \left(1 + a_t \times \frac{p_t - p_{t-1}}{p_{t-1}}\right) \frac{p_{t-1}}{p_{t-n}}. \quad (5)$$

수식에서 보이다시피, 이 보상 함수는 주식 수익율의 변형이다. Wang et al.(2017)은 n 을 200으로 설정했다. 공정한 비교를 위해 본 연구에서도 n 을 200으로 설정했다. n 을 크게 설정하면 주가의 장기 추세를 반영할 수 있다. 테스트 기간 동안 모든 모델의 성과는 일일 수익률의 합계, 즉 'total profit'으로 측정된다. 수식 (6)과 수식 (7)에서 알 수 있다시피 이를 통해 모델을 직관적으로 평가할 수 있다.

$$profit_t = a_t \times \frac{p_t - p_{t-1}}{p_{t-1}} \quad (6)$$

$$Total\ profit = \sum_t profit_t \quad (7)$$

이익(profit)은 좋은 행동을 선택하는지 여부와 다음날의 주식 추세를 잘 예측하는지 여부를 나타내는 지표로 사용된다. 예를 들어, 수식 (7)에 따르면 전체 기간 동안 거래를 하지 않으면 (즉, HOLD 작업 만 선택된 경우) 총 이익(total profit)은 0입니다.

우리의 거래 시스템은 $t - 200$ 에서 $t - 1$ 시점까지의 마감 가격을 분석함으로써 t 시점에서의 거래 행동을 결정하는 시스템이다. 이 거래 시스템은 시스템이 하루에 한 번 거래할 수 있는 제약 조건을 포함하여 당일 거래(day trading)에 기반한다. 또한, 주식을 거래할 때, 시간, 날짜 및 주식의 수에 관계없이 거래가 가능하다고 가정한다. 거래 비용은 0으로 설정되고 공매도는 허용되며 거래가 거래자의 자산과 상황의 영향을 받지 않는다고 가정합니다.

4. 제안방법

4.1 거래할 주식 수 정하기

본 연구에서는 거래할 주식을 정하는 세 가지 방법을 제안한다. 이 방법은 총 이익을 극대화하기 위해 매 순간 Q-value와 DNN regressor로 거래할 주식 수를 예측하여 정한다. 이때, 주식 수는 연속된 숫자(continuous number)로 결정된다. 연속된 숫자는 1 또는 2와 같은 정수가 아니라 네트워크의 출력값에 따라 유리수로 결정된다는 것을 의미한다. Jiang, Xu and Liang (2017)은 포트폴리오를 구성하는 모든 주식에 딥러닝으로 가중치를 부여함으로써 포트폴리오를 최적화한다. 이들은 강화학습에서 이산 행동(discrete action)으로 인해 발생하는 문제를 관리하기 위해 포트폴리오에 연속적인 가중치(continuous weighting)를 적용한다. Pendharkar & Cusatis (2018)는 연속 행동이 이산 행동보다 주식 거래에서 더 효과적임을 보여준다. 따라서 여기서 소개하는 DNN regressor는 연속적인 주식수를 예측한다. 이렇게 연속된 개수의 주식을 거래함으로써 이산 행동의 위험을 규제할 수 있다.

거래할 수 있는 주식 개수는 매 순간 데이터 패턴에 의해 심각하게 영향을 받지 않고 시장에 심각한 영향을 미치지 않도록 고정된 수 (L)로 제한된다. 이 제한은 넓은 학습 범위를 적절하게 제한하므로 학습 속도가 향상된다. 이 연구에서, L 은 실험에 근거하여 10의 값을 할당했다; 이 값은 거래자의 니즈와

자산을 기준으로 변경할 수 있다. 수식 (8)과 (9)에서 볼 수 있듯이 보상 함수와 수익 함수는 시간 t 에서 예측된 주식수, num_t 를 포함하여 계산된다.

$$r_t = num_t \times \left(1 + a_t \times \frac{p_t - p_{t-1}}{p_{t-1}}\right) \frac{p_{t-1}}{p_{t-n}}, \quad (8)$$

$$profit_t = num_t \times a_t \times \frac{p_t - p_{t-1}}{p_{t-1}}. \quad (9)$$

우리는 다음 세 가지 방법을 사용하여 거래할 적절한 주식 수를 결정합니다.

4.1.1 Q-value를 이용한 주식 수 결정

이 방법에서는 행동의 신뢰성에 따라 주식 수를 결정한다. Deep Q-learning에서, 행동은 Q-value에 의해 결정된다. 선택된 Q-value가 다른 값보다 충분히 크면 선택된 행동이 신뢰할 수 있다고 가정합니다.

첫 번째로 *Softmax* 함수를 사용하여 Q-value의 비율에 따라 주식 수를 결정하여 NumQ 방법이라고 부른다. *Softmax* 함수는 값을 양수로 만들고 값이 0보다 크면 큰 값을 더 큰 값으로 스케일하는 지수 함수로 구성되어 선택한 Q-value의 비율을 보다 효과적으로 확인할 수 있다. $q_{j,l}$ 를 l 번째 레이어의 j 번째 뉴런의 결과값이라 할 때 *Softmax* 함수 수식은 다음과 같다:

$$Softmax_{j,l}(q) = \frac{e^{q_{j,l}}}{\sum_k e^{q_{k,l}}} \quad (10)$$

Q-value의 출력값을 *Softmax* 함수에 넣어 거래할 주식 수를 계산하고 선택한 Q-value에 따라 주식 수를 선택한다. 예를 들어, 구매 행동이 선택되면 구매 행동에 대한 주식 수가 선택된다.

그림 2에서 보는 것과 같이, 모든 층은 완전히 연결된 층으로 구성된다. 이 구조는 두 개의 분기(branch)로 구성되어 있는데 행동을 결정하는 분기와 행동 당 주식 수를 결정하는 분기가 있다. 적절한 행동을 찾기 위해 분기가 업데이트되면 그 분기를 *행동 분기(action branch)*라고 부른다. 마찬가지로, 분기가 주식 수를 예측하는 데 사용되면 *개수 분기(number branch)*이라고 부른다. 네트워크의 세부사항은 수식 (11)에서 (16)에 나타나 있다. 이때, W 는 가중치(weight) 벡터, I_t 는 시간 t 에서의 입력 벡터, b 가 바이어스, Q_{action} 는 행동의 Q-value, R_{num} 이 주식수의 비율이며, num_t 는 시간 t 에서의 주식 수이다.

행동 분기의 처음 세 개의 층은 활성화함수로 *Relu* 함수 (Nair & Hinton, 2010)를 사용하는 반면, 행동 분기의 마지막 층은 수식 (11) - (14)와 같이 선형 함수를 사용한다. R_{num} 은 수식 (15)와 같이 *Sigmoid* 함수 및 *Softmax* 함수를 적용한 $fc3$ 의 출력값으로 계산된다. *Sigmoid* 함수는 값을 정규화 하는 데 사용된다. 주식 수, num_t 는 L 과 $R_{num}(s_t, a_t^*)$ 에 의해 결정되고 $R_{num}(s_t, a_t^*)$ 은 수식 (16)에서와 같이 Q_{action} 을 최대화하는 동작 a^* 에 의해 결정된다. 이후 논문에서 L 은 설명이 없는 경우에도 위와 같이 거래 가능한 최대 주식 수를

나타낸다.

$$fc1 = Relu(W_1 I_t + b_1) \quad (11)$$

$$fc2 = Relu(W_2 \times fc1 + b_2) \quad (12)$$

$$fc3 = W_3 \times fc2 + b_3 \quad (13)$$

$$Q_{action}(s_t, a_t) = W_4 \times Relu(fc3) + b_4 \quad (14)$$

$$R_{num}(s_t, a_t) = Softmax(W_4 \times Sigmoid(fc3) + b_4) \quad (15)$$

$$num_t = R_{num}(s_t, a_t^*) \times L \text{ where } a_t^* = \operatorname{argmax} Q_{action}(s_t, a_t) \quad (16)$$

DQN의 완전 연결 레이어(fully-connected layer)의 구성으로는 첫 번째 레이어 (fc1)에 200개의 뉴런이 있고 두 번째 (fc2)에 100개의 뉴런이 있고 세 번째 (fc3) 레이어에는 50개의 뉴런이 있다. 각 계층의 뉴런 수는 시행 착오(trial and error)에 의해 결정된다. 마지막 레이어는 출력 레이어이며 세 개의 뉴런이 있고 각각 세 가지 행동 (BUY, HOLD 및 SELL)을 의미한다. 즉, 행동 분기의 마지막 레이어에 있는 각 뉴런은 세 가지 행동의 가능성을 반영한다.




그림 2. NumQ 방법의 구조

4.1.2 행동 의존적인 DNN regressor로 주식 수 결정

이 방법에서는 개수를 정하는 신경망을 구성하여 주식 수를 결정한다. 행동 분기의 가중치를 사용하는 대신 별도의 개수 분기를 추가하고 이 분기를 주식의 개수에 대해서만 최적화한다. 기능의 일관성을 유지하기 위해 두 번째 레이어에서 개수 분기를 추가한다. 따라서 개수 분기는 행동 분기의 특징을 공유할 수 있으며 이 방법을 'NumDReg - AD'라고 한다. 네트워크는 수식 (17)과 (18)과 같이 개별적으로 업데이트되며 4.1.1장과 동일한 표기법을 사용한다.

$$Q_{action}(s_t, a_t) := Q_{action}(s_t, a_t) + \theta * \{r_t + \gamma Q_{action}(s_{t+1}, a') - Q_{action}(s_t, a_t)\}, \quad (17)$$

$$R_{num}(s_t, a_t) := R_{num}(s_t, a_t) + \theta * \{r_t + \gamma R_{num}(s_{t+1}, a) - R_{num}(s_t, a_t)\}. \quad (18)$$

행동 분기를 계산하는 과정은 4.1.1 장과 동일하고, 개수 분기는 4.1.1 절과 같은 표기법을 사용하여 수식 (19) ~ (21)로 표현된다.

$$fc2_{num} = Relu(W_2 \times fc1 + b_2) \quad (19)$$

$$fc3_{num} = Sigmoid(W_3 \times fc2_{num} + b_3) \quad (20)$$

$$R_{num}(s_t, a_t) = Softmax(W_4 \times fc3_{num} + b_4) \quad (21)$$

행동 분기와 개수 분기는 유사한 계층 구조를 갖는다. 두 분기는 모두 세 개의 레이어로 구성되고 각각의 활성화 함수는 동일한 순서로 사용된다. 첫 번째 레이어는 *Relu* 함수를 활성화 함수로 사용한다. 행동 분기는 두 번째, 세 번째

레이어에서도 *Relu* 함수를 사용하고 마지막 레이어에서는 선형 함수를 사용한다. 반면, 개수 분기는 수식 (19) ~ (21)에 기술된 바와 같이, 레이어 순서대로 *Relu*, *Sigmoid*, 그리고 *Softmax* 함수를 취한다. 주식수는 4.1.1 절과 같은 방법으로 계산된다. DNN regressor를 추가하면 이 네트워크에는 행동 분기의 뉴런과 DNN regressor의 개수 분기에 있는 뉴런이 모두 포함된다. 증가된 뉴런 개수는 과적합을 유발할 수 있다 (Aquino, Chamhum Salomão, & Azevedo, 2016, Taghavifar, Taghavifar, Mardani, & Mohebbi, 2014). 따라서 각 레이어의 뉴런 수는 첫 번째 레이어 ($fc1$) 100, 두 번째 ($fc2$, $fc2_{num}$) 50, 세 번째 ($fc3$, $fc3_{num}$) 레이어 20으로 조정된다. 마지막 레이어는 출력 레이어이며 기존과 마찬가지로 세 개의 뉴런이 있다. 그림 3은 전체 구조를 나타낸다.




그림 3. NumDReg – AD 방법의 구조

NumDReg – AD의 학습 범위가 너무 커서 NumQ보다 각 계층의 뉴런 수가 감소시켜도 바로 솔루션을 제공할 수 없다. 따라서 네트워크를 단계별로

학습한다. 이 방법을 NumDReg – AD with three – step training 라고 한다. 전체 구조는 NumDReg – AD 방법과 동일한데 훈련 과정을 세 단계로 구분한다. 첫 번째 단계에서 뉴런 개수를 감소시켜 NumDReg 의 행동 분기 뉴런 개수와 동일하게 만든 NumQ 방법으로 가중치를 훈련하여 행동에 대한 Q-value 정보를 얻는다. 다음으로, 행동 분기에 대한 가중치를 고정하고 개수 분기의 가중치를 훈련한다. 최종적으로 end-to-end process를 사용하여 전체 가중치를 파인 튜닝(fine-tuning)합니다. 이 과정은 그림 4에 설명되어 있다.




그림 4. NumDReg – AD with three – step training의 훈련과정 순서도

4.1.3 행동 독립적인 DNN regressor로 주식 수 결정

NumDReg – AD 방법으로 개수 분기를 추가하여 개수를 결정하는 자체 네트워크를 가지게 되었다. 그러나 가장 큰 Q-value에 의해 선택된 행동에 따라 주식 수가 결정되기 때문에 개수는 여전히 행동에 영향을 받는다. 따라서 본 연구에서는 행동에 관계없이 개수에 대한 계층을 구성하여 개수가 결정되도록 하였고 이 방법을 'NumDReg – ID'라고 한다. 이를 통해 선택한 행동에 영향을 받지 않고 금융 시장의 특성에만 영향을 받는 분기를 구성할 수 있다. 이 방법에서 개수 분기의 출력 크기는 기존의 3 대신 1로 설정된다. 개수 분기의 출력 크기를 제외하고는 NumDReg – AD 방법과 동일하다. 구조는 그림 5에 설명되어 있고 훈련 과정은 기존과 마찬가지로 3 단계로 나뉘어지고 이를 NumDReg – ID with three – step training라고 부른다.




그림 5. NumDReg – ID with three – step training의 훈련과정 순서도

4.2 혼란스러운 시장에서의 행동 전략

본 연구에서는 시장이 혼란스럽다는 신호를 받으면 사전에 정의된 행동으로 매매하는 ‘행동 전략(action strategies)’을 이용해 시장 상황이 확고한 결정을 내리는 것이 어려울 때, 불확실한 정보로 인한 손실을 최소화한다. 이 방법에서 Q-value는 행동의 견고성(robustness)으로 간주되며 시장이 혼란스러운지를 결정하기 위해 Q-value의 확률을 비교한다. BUY를 할 때의 가치와 SELL을 할

때의 가치가 큰 차이가 나지 않는다면 시장에 명확한 추세가 없는 것으로 간주하고 특정 행동을 제공한다. 그렇지 않은 경우 가장 큰 Q 값을 가진 작업을 일반적인 경우로 선택합니다. 좀 더 구체적으로, BUY할 확률 $\frac{Q(s_t, a_{BUY})}{\sum |Q(s_t, a)|}$ 와 SELL할 확률 $\frac{Q(s_t, a_{SELL})}{\sum |Q(s_t, a)|}$ 의 차이가 미리 결정된 임계 값(threshold)보다 낮으면 시장이 혼란스럽다는 신호로 받아드려 전략에 따라 조치를 취한다. 임계 값은 경험에 의해 결정되며 행동 전략의 함수는 수식 (22)에 주어진다.

$$\frac{|Q(s_t, a_{BUY}) - Q(s_t, a_{SELL})|}{\sum |Q(s_t, a)|} < threshold. \quad (22)$$

우리는 주어진 행동이 BUY, HOLD 또는 SELL인 세 가지 행동 전략을 사용하고 임계 값은 주어진다. 행동 전략을 포함하는 훈련 알고리즘은 알고리즘 1에서 표현된다. 각 에피소드에서, 우선 상태 s_t 를 설정하고 Q-network 및 DNN regressor를 훈련하여 행동에 대한 Q-value 및 개수에 대한 비율을 얻는다. 이 값들을 적용한 수식 (22)에 따라 시장이 혼란스러운지 신호를 확인하고 행동 전략을 적용해 행동을 결정한다. BUY 신호와 SELL 신호의 확률 차이가 임계 값보다 낮으면 행동은 미리 결정된 행동으로 설정된다. 그러나 그 차이가 임계 값보다 높으면, 그 행동은 greedy하게 선택된다.

알고리즘 1 행동 전략을 포함한 Q learning

Initialize the Q network and load the pretrained network.

$Total\ profit = 0$

1: **for** each episode **do**:

2: Set state s_t ;

3: Obtain the Q-values for the action and the number in accordance with the Q-network.

4: **if** $\frac{|Q(s_t, a_{BUY}) - Q(s_t, a_{SELL})|}{\sum |Q(s_t, a)|} < threshold$, **then**:

5: The action is given by the strategy;

6: **else**:

7: Action $a_t = \operatorname{argmax} \{Q(s_t, a)\}$;

8: Set next state s_{t+1} ;

9: Calculate r_t and $profit_t$;

10: Store memory (s_t, a_t, r_t, s_{t+1}) in buffer.

11: **for** each mini-batch sample **do**:

12: $Q(s_t, a_t) \leftarrow Q(s_t, a_t) + learning\ rate * \left(r_t + \gamma Q(s_{t+1}, a) - Q(s_t, a_t) \right)$,

13: $Total\ profit \leftarrow Total\ profit + profit_t$.

14: **end for**

15: **end for**

4.3 인덱스 구성 주식을 이용한 이전 학습

인덱스 구성 요소의 일부분을 사용하여 이전 학습을 도입한다. 금융 시장은 매우 변동적이고 이렇게 변동성이 큰 타겟 데이터만으로는 학습이 충분하지 않아 금융 데이터를 효율적으로 훈련하기가 어렵다. 따라서 문제를 해결하기

위해 이전 학습을 통해 모델을 사전 훈련(pre-training)한다.

이전 학습은 사전 훈련된 모델을 이전하여 타겟 데이터를 학습하는 방법이다.

이전 학습의 한 방법으로 타겟 데이터와는 다른 데이터를 사용하지만 해당 데이터와 관련이 있는 데이터를 사용하는 방법이 있다 (Pan & Yang, 2010). 이 접근법은 학습할 데이터나 정보가 충분하지 않을 때 유용하다 (Ghosh, Laksana, Morency, & Scherer, 2016; Lu et al., 2014; Wu, Lance, & Parsons, 2013).

본 연구에서는 타겟 데이터인 인덱스를 학습하기 위해 인덱스의 구성 주식을 활용하여 이전 학습을 하였다. 하지만, 시간적인 제약 때문에 모든 구성 주식을 사용할 수 없었다. 따라서, 모든 구성 주식을 사용하는 대신에 두 가지 측정 방법으로 인덱스와 그 구성 주식 간의 관계를 측정했고 서로 다른 관계를 가진 구성 주식의 그룹들이 선택되었다. 그런 다음 그룹간의 효과를 비교한다.

두 가지 측정 방법으로는 상관 관계와 신경망의 복원 오차를 사용했다. 상관 관계는 금융 시장의 주식 간 관련성을 분석하는데 자주 사용되는 통계 지표이다. σ_X 가 X 의 표준 편차, σ_Y 가 Y 의 표준 편차, $cov(X,Y)$ 가 X 와 Y 사이의 공분산일 때, 두 주식, X 와 Y 사이의 상관 관계, ρ 는 수식 (23)과 같다.

$$\rho_{X,Y} = \frac{cov(X,Y)}{\sigma_X \sigma_Y}, \quad (23)$$

이 방법에서 신경망은 서로 다른 데이터를 복원하여 데이터 패턴 간의 관련성을 측정하는데 사용된다. 신경망은 인덱스의 구성 주식들로 인덱스를

복원하게 학습되며 두 개의 레이어로 구성된다. 훈련 데이터가 X 이고 출력이 Y 이고 하나의 은닉층(hidden layer)만 있는 경우 두 레이어를 각각 수식 (24) 및 (25)와 같이 설명할 수 있다. 이때, w^1 와 w^2 는 가중치 벡터, b^1 와 b^2 는 바이어스, 그리고 f^1 와 f^2 는 활성화 함수를 뜻한다.

$$Z = f^1 (W^1 X + b^1) \quad (24)$$

$$Y = f^2 (W^2 Z + b^2) \quad (25)$$

목표는 $X = Y$ 가 되게끔 가중치 행렬을 조정하는 것이다. 이 신경망을 학습하여 결과적으로 복원 오차에 따라 인덱스와 인덱스 구성 함수의 관계를 측정한다. 적절한 가중치 행렬을 찾기 위해 이 네트워크는 다섯 개의 뉴런이 있는 하나의 은닉층으로 구성되어 있다. 활성화 함수 f^1 과 f^2 는 *Relu*이고 손실 함수(loss function)는 평균 제곱 오차 (MSE)이다.

이 두 가지 방법을 통해 우리는 Heaton, Polson, & Witte (2017)에서 영감을 얻은 방식으로 구성 주식을 세 가지 그룹으로 선택한다. 세 가지 그룹은 높은 관계의 구성 주식, 높은 관계 절반과 낮은 관계 절반으로 구성된 구성 주식, 낮은 관계의 구성 주식이다. 높은 관계의 구성 주식과 낮은 관계의 구성 주식은 (이하 *높은 관계 그룹*, *낮은 관계 그룹*) 인덱스 주식과의 관련성이 높거나 낮은 주식으로 구성된다. 높은 관계 절반과 낮은 관계 절반으로 구성된 구성 주식 (이하 *높고 낮은 관계 그룹*)은 절반은 인덱스와 높은 관계에 있고, 나머지 절반은 인덱스와 낮은 관계에 있는 주식들로 구성된다. 따라서 두 가지

방법으로 각각 세 가지 그룹을 선택해 총 6 개의 그룹을 만든다.

상관 관계의 경우, 인덱스와 구성 주식 간의 상관 관계를 기반으로 3 개의 그룹이 생성된다. 높은 관계 그룹은 인덱스와의 상관 관계가 높은 순서로 주식을 선택한다. 유사하게, 낮은 관계 그룹은 인덱스와의 상관 관계가 낮은 순서로 주식이 선택된다. 마지막으로 높고 낮은 관계 그룹은 높은 상관 관계의 순서로 그룹의 절반을 선택하고 낮은 상관 관계 순서로 나머지 절반을 선택한다. 신경망의 경우, 복원 오차 인 MSE를 기반으로 3 개의 그룹이 생성된다. 높은 관계 그룹은 낮은 MSE를 갖는 주식이 선택되고, 낮은 관계 그룹은 높은 MSE를 갖는 주식이 선택된다. 높고 낮은 관계 그룹은 MSE가 낮은 주식의 절반과 MSE가 높은 주식의 절반이 선택된다.

주식을 선택한 이후에, 선택된 각 그룹의 모델을 사전 훈련한다. 각 그룹에서 모든 주식은 개별적으로 사전 훈련되지만 가중치를 공유한다. 이러한 사전 훈련된 가중치를 사용하여 최종적으로 인덱스로 수익을 창출하는 기본 모델을 훈련한다. 이 방법의 효율성을 검증하기 위해 S & P500, HSI, EuroStoxx50 및 KOSPI의 네 가지 인덱스를 사용한다. 인덱스에 포함된 구성 주식의 수에 따라 인덱스마다 다른 개수의 구성 주식이 각 그룹에 선택된다. 그림 6은 이전 학습의 학습 과정을 보여준다.




그림 6. 이전학습의 학습 과정

최종 모델은 알고리즘 2에 제시된다. 학습은 사전 훈련할 데이터를 결정하면서 시작된다. 이 학습은 4가지 인덱스에 대해 동일하게 적용된다. 우선, 인덱스와 그 구성 주식 사이의 상관 관계와 신경망 복원오차 MSE를 계산한다. 이 두 가지 측정 방법과 서로 다른 세 가지 관계에 따라 6 개의 그룹을 만든다. 6개의 그룹을 각각 사전 훈련한 뒤에 그 가중치를 이용해 DNN regressor가 추가된 DQN에 이전 학습을 적용한다. DNN regressor는 거래할 주식 개수를 정하고 DQN의 행동은 행동전략에 따라 결정된다. 알고리즘은 개수를 정하는

방법을 어떤 것을 사용하는지에 따라 다르다. 최종적으로 총 이익이 가장 높은 그룹, 방법, 혹은 전략이 선택된다.

알고리즘 2 이전 학습, 매매할 주식 개수 결정, 그리고 행동 전략이 포함된 전체 학습 과정

- 1: Load the index data and the index component stocks;
 - 2: Calculate the correlation between the index and the index components stocks or calculate the MSE between them with the neural network;
 - 3: Create the six groups with the highest or lowest relationship or both using correlation and the MSE;
 - 4: Select the best group among the six groups;
 - 5: Pretrain the model including NumQ or NumDReg – AD with the chosen group;
 - 6: **if** NumQ, **then**:
 - 7: Load NumQ weights pretrained by transfer learning;
 - 8: Train the model, including NumQ with the action strategy;
 - 9: **else if** NumDReg – AD, **then**:
 - 10: Load NumDReg – AD weights pretrained by transfer learning;
 - 11: Train the model, including NumDReg – AD with the action strategy;
 - 12: **else if** NumDReg – AD with three – step training, **then**:
 - 13: Load NumQ weights pretrained by transfer learning;
 - 14: Freeze NumQ weights and only train the number branch based on the NumDReg – AD algorithm;
 - 15: Complete an end-to-end process with the action strategy;
 - 16: **else if** NumDReg – ID, **then**:
 - 17: Load NumQ weights pretrained by transfer learning;
 - 18: Freeze NumQ weights and only train the number branch based on the NumDReg – ID algorithm;
 - 19: Complete an end-to-end process with the action strategy;
-

5. 실험 결과 및 비교

본 논문에서는 S&P500, HSI, Eurostoxx50 및 KOSPI 등 네 가지 인덱스 주식을 사용하여 제안된 방법들을 검증하기 위한 다양한 실험을 수행한다. 모든 주식 데이터는 *Thomson Reuters*와 *Yahoo! Finance*에서 다운로드 됐다. 누락된 값은 전날의 값을 사용하여 지정된다.

표 1에서 볼 수 있듯이 인덱스 데이터를 사용한 훈련을 ‘주 훈련(*main training*)’이라고 한다. 훈련 기간은 전체 데이터 기간의 60% 정도를 차지한다. 나머지 40%는 테스트 데이터로 사용된다. 인덱스의 구성 주식을 사용한 이전 학습을 ‘사전 학습(*pretraining*)’이라고 한다. 훈련 기간은 주 훈련의 훈련 기간의 80%이고 나머지 20%는 확인(*validation*) 데이터로 사용된다. 전체 데이터 기간에는 부동산 거품, 일본 (1985-89), 태국, 말레이시아 및 다른 아시아 국가 (1992-1997)의 주식 시장 버블; 닷컴 버블 (1992-2002); 미국의 장외 시장 버블 (1995-2000); S&L 사태(1980년대)와 같은 다양한 금융 이슈가 포함된다 (DeLong & Magin, 2006; Flood, 2012, Kindleberger & Aliber, 2005). 또한 글로벌 금융 위기 (2007-08) 도 포함된다 (Flood, 2012).

4 개의 인덱스 주식은 같은 기간 동안 다른 패턴을 가지고 있다. 인덱스의 움직임과 상세한 훈련, 테스트 기간은 그림 7과 표 1에 설명되어 있다. 그림

7에서 알 수 있듯이 S&P500 지수는 인덱스들 중 가장 점진적인 증가를 보여준다. HSI와 KOSPI 역시 상승 추세를 보이고 있지만 S&P500보다 변동성이 크다. Euro stoxx50은 테스트 기간 동안 특별한 추세를 보이지 않지만 다양한 움직임을 보여준다. 2장에서 언급했듯이 이러한 금융 가격 추세를 파악하기 위해 window size를 200 일로 설정했다.




그림 7. 네 가지 인덱스의 움직임

표 1. 데이터 종류

Main training		Training period		Test period
Pretraining	Training	Validation	x	
S&P500 index (SP500)	Jan 1, 1987–Nov 4, 2002	Nov 5, 2002–Aug 10, 2006	Aug 11, 2006–Dec 31, 2017	
Hang Seng Index (HSI)	Jan 2, 2001–May 2, 2008	May 3, 2008–Jul 21, 2009	Jul 22, 2009–Dec 29, 2017	
EuroStoxx50 index	Apr 05, 1991–Feb 19, 2003	Feb 20, 2003–Jul 13, 2005	Feb 21, 2003–Dec 29, 2017	
Korea Stock Price Index (KOSPI)	Jul 1, 1997–Jul 11, 2006	Jul 12, 2006–May 05, 2008	Mar 06, 2008–Dec 28, 2017	

각 minibatch마다 가중치가 업데이트되는 Mini-batch learning (Cotter, Shamir, Srebro, Sridharan, 2011, Feyzmahavavian, Aytekin, & Johansson, 2016, Li, Zhang, Chen 및 Smola, 2014)이 사전 훈련에 사용된다. 주 교육의 경우 가중치가 입력마다 업데이트되는 온라인 학습(online learning)을 사용한다 (Duchi & Singer, 2009, Shalev-Shwartz, Singer, & Ng, 2004, Sudo, Sato, & Hasegawa, 2009, Vijayakumar, D'souza, & Schaal, 2005). Adam optimizer (Kingma & Ba, 2014)가 최적화 함수로 사용된다. 네트워크는 4개의 계층으로 구성되고 하이퍼파라미터는 학습률 0.0001, 감마 0.85, 배치 크기 64로 설정되었다. End-to-end process의 학습률은 NumDReg – AD with three – step training 의 경우 0.0000001로, NumDReg – ID with three – step training 는

0.00001로 설정됐다. 모든 하이퍼파라미터는 수동 검색(manual search) (Bergstra & Yoshua Bengio, 2012)에 의해 식별된 다음 시행 착오에 의해 결정된다.

표 2는 편의상 모델의 약어를 제공한다. 모델이 시장을 능가하는지 여부를 확인하기 위해 MKT 모델을 사용한다. MKT 모델은 전체 기간동안 인덱스를 구입한 다음 수식 (6)과 (7)을 사용하여 이익과 총 이익을 계산한다. RL 모델은 사전 훈련을 하지 않은채 인덱스 데이터를 사용하여 강화학습을 통해 거래하는 모델이다. 이는 Wang 등 (2017)이 제안한 모델과도 일치한다. IDX는 타겟 데이터인 인덱스를 사용한 사전 훈련이 포함된다. CR 및 NE 모델은 이전 학습을 활용한 사전 훈련이 포함된다. 이들은 구성 주식을 선택하는 기준에 따라 구분되는데 상관 관계를 사용하여 구성 주식을 선택하는 경우 CR 모델이라 하고 신경망 복원오차를 사용하는 경우 NE 모델이라 한다. NQ 및 NDA 모델은 주식 수를 정하는 방법 NumQ와 NumDReg – AD를 의미하고 각 방법은 사전 훈련없이 주 훈련에 사용된다. 사전 훈련이 NE 구성 주식을 사용하여 수행되고 또한 주식 수를 정하는 것을 포함하는 경우, NENQ 및 NENDA 모델이라 한다. NENDA3 모델은 NENDA에 단계별 훈련을 적용한 NumDReg – AD with three – step training 를 나타낸다. NENDI3는 NumDReg – ID with three – step training 를 의미한다. 마지막으로, NENDI3-BUY, NENDI3-HOLD 및 NENDI3-SELL은 NENDI3 모델에 행동 전략을 적용한 것이다.

표 2. 모델 약어

Abbrev- -iation	Pretrained data measure	Main training data	Pretrained Number method	Number method	Step- wise trainin g	Action strate gy
MKT	N/A	N/A	N/A	N/A	N/A	N/A
RL	N/A	Index	N/A	N/A	N/A	N/A
IDX	Index	Index	N/A	N/A	N/A	N/A
CR	Correlation	Index	N/A	N/A	N/A	N/A
NE	Neural Network	Index	N/A	N/A	N/A	N/A
NQ	NE	Index	N/A	NumQ	N/A	N/A
NENQ	NE	Index	NumQ	NumQ	N/A	N/A
NDA	NE	Index	N/A	NumDReg – AD	N/A	N/A
NENDA	NE	Index	NumDReg – AD	NumDReg – AD	N/A	N/A
NENDA 3	NE	Index	NumQ	NumDReg – AD	o	N/A
NENDI3	NE	Index	NumQ	NumDReg – ID	o	N/A
NENDI3 –BUY	NE	Index	NumQ	NumDReg – ID	o	Buy
NENDI3 –HOLD	NE	Index	NumQ	NumDReg – ID	o	Hold
NENDI3 –SELL	NE	Index	NumQ	NumDReg – ID	o	Sell

5.1 인덱스와 관련된 구성 주식을 사용한 이전 학습

모델을 사전 훈련하기 위해 S&P500, KOSPI, HSI 및 Eurostoxx50의 구성 주식 중 각 인덱스마다 구성 주식을 상관 관계와 신경망 복원오차에 따라 선택한다. 인덱스 구성 주식 중 전체 기간에 대하여 데이터가 존재하는 주식은 S&P500에는 304 종목, KOSPI에는 342 종목이 있다. 반면, HSI가 25 종목, Eurostoxx50이 30 종목이 있는데 이는 S&P500, KOSPI의 사용 가능한 구성 주식 수보다 적다. 따라서 이러한 차이를 고려하여 S&P500과 KOSPI는 10개를 HSI와 Eurostoxx50은 6개를 선택했고 각각 세 개의 그룹을 생성했다. 표 3은 주식 종목명의 약칭을 사용하여 선택된 회사를 나열했다. *High*, *High and Low*, 그리고 *Low*는 인덱스 주식과 선택한 구성 주식 6 개 혹은 10 개 사이의 관계를 나타낸다. *High*는 인덱스와 매우 관련이 높은 구성 주식 (즉, 4.3장에서 언급한 바와 같이 상관 관계가 높고 복원 오차가 작은 주식)을 나타낸다. *High and Low*는 인덱스와 높은 관계가 있는 구성 주식 절반과 낮은 관계가 있는 구성 주식 절반을 나타낸다. *Low*는 인덱스와 상대적으로 낮은 관련이 있는 구성 주식 (즉, 상관 관계가 낮고 복원 오차가 큰 주식)을 나타낸다. 우선 선택한 구성 주식을 사용하여 모델을 사전 훈련한다.

표 3. 상관관계와 신경망 복원오차에 따라 선택된 주식 종목들의 약칭

S&P500				KOSPI				
Correlation		Neural Network		Correlation		Neural Network		
High	Low	High	Low	High	Low	High	Low	
1	AXP	MAC	JPM	AJG	005930.KS	002420.KS	007590.KS	006040.KS
2	MS	HCN	PG	RJF	016360.KS	003060.KS	002690.KS	008930.KS
3	BK	SPG	HON	ECL	005940.KS	015540.KS	009810.KS	002990.KS
4	EMR	SCG	ABT	DHR	006800.KS	005610.KS	003920.KS	011200.KS
5	RJF	FL	JNJ	XRX	003540.KS	006110.KS	012750.KS	05930.KS
6	DOV	SIG	KMB	MNST	009150.KS	012170.KS	008730.KS	010060.KS
7	PPG	HCP	TRV	PVH	005490.KS	000950.KS	000810.KS	009970.KS
8	BBT	WEC	ADP	ROST	003470.KS	002070.KS	003460.KS	007310.KS
9	ETN	KIM	DOV	MKC	005380.KS	004960.KS	006890.KS	002350.KS
10	C	SO	CAH	ETR	016610.KS	011150.KS	103140.KS	004490.KS
HSI				EuroStoxx50				
Correlation		Neural Network		Correlation		Neural Network		
High	Low	High	Low	High	Low	High	Low	
1	0001.HK	0002.HK	0002.HK	0005.HK	ALVG.DE	AD.AS	AXAF.PA	BASFn.DE
2	0005.HK	0006.HK	0012.HK	0175.HK	AXAF.PA	DANO.PA	DBKGn.DE	ESSI.PA
3	0012.HK	0175.HK	0016.HK	0267.HK	DAIGn.DE	ESSI.PA	ISP.MI	SAF.PA
4	0016.HK	1038.HK	0019.HK	0941.HK	DBKGn.DE	SAF.PA	NOKIA.HE	SGEF.PA
5	0857.HK	1044.HK	0023.HK	1038.HK	SIEGn.DE	SGEF.PA	PHG.AS	VOWG_p.DE
6	0941.HK	1093.HK	0386.HK	1109.HK	SOGN.PA	URW.AS	SGOB.PA	URW.AS

선택한 구성 주식들을 사용하여 모델을 사전 훈련한 후 인덱스를 사용하여 주 모델을 학습한다. 그룹들의 총 수익을 비교하여 사전 훈련에 가장 효과적인 그룹을 찾는다.

표 4와 그림 8에서와 같이 모든 사전 훈련은 전체 이익을 개선하는 데 효과적이었다. 실제로, 모든 사전 훈련된 모델의 총 수익은 MKT 모델을 능가한다. CR 모델을 NE 모델과 비교할 때 NE 총 수익은 대부분의 경우 CR 총 수익보다 4 % ~ 40 % 높다. S&P500에서 NE의 High, High and Low, Low에 대한 총 수익은 CR에 대한 High, High and Low, Low 총 수익보다 각각 40 %, 36 % 및 11 % 높다. KOSPI에서 NE의 총 수익은 CR보다 High, High and Low, Low에서 각각 4 %, 49 %, 38 % 높다. HSI에서는 NE의 High, High and Low 총 수익이 CR의 총 수익보다 각각 7 % 및 10 % 높다. 그러나 NE Low의 총 수익은 CR 총 수익보다 13 % 낮다. EuroStoxx50에서 High, High and Low, Low에 대한 NE 총 수익은 CR보다 각각 31 %, 33 % 및 25 % 높다. 따라서 신경망은 인덱스와 그 구성 주식 간의 관계를 모델링하는 데 효과적이라고 볼 수 있다.

이와 동시에, 인덱스와의 관계에 따라 모델을 비교했다. 표 4에 따르면 S&P500과 KOSPI의 경우 Low 모델이 High 모델보다 더 많은 수익을 올리는 반면 HSI 및 EuroStoxx50의 경우 High 모델은 주식을 선택하는 측정 방법에 상관없이 Low 모델보다 더 많은 수익을 얻는다. 따라서 S&P500 지수와

KOSPI 지수와 같이 구성 주식이 충분할 경우 인덱스와의 관계가 낮은 주식을 사용하는 것이 효과적임을 알 수 있다. 그러나 HSI 및 EuroStoxx50과 같은 소량의 구성 주식이 있는 경우 인덱스와의 높은 관계가 더 효과적이었다. S&P500과 KOSPI의 경우, 선택한 구성 주식 비중이 전체 구성 주식의 약 3%, HSI와 Eurostoxx50은 20% 이상이다. 이로써, 구성 주식 비중에 따라 총 수익을 증가시키는 인덱스와 구성 주식 간의 관계가 다른 것을 확인하였다.

결과적으로 실험 결과를 통해 NE Low 모델이 S&P500과 KOSPI에 가장 효과적이라는 것을 발견했다. 이 경우 NE Low모델은 RL 모델에 비해 총 이익이 84% 및 275% 증가했고 IDX 모델보다 17% 및 218% 높으며 MKT 모델보다 65% 및 234% 더 높다. 반면에 HSI 및 EuroStoxx50에서는 NE High 모델이 가장 효과적이다. 이 경우에는 RL 모델에 비해 총 수익을 93 % 및 153 % 증가시키고 IDX 모델보다 25 % 및 49 % 높으며 MKT 모델보다 160 % 및 5 배 더 높다. 따라서, 사전 훈련 방법은 총 이익을 개선하는 데 도움이 되는 것으로 확인했다. 또한 인덱스 자체보다는 구성 주식으로 사전 훈련하는 것이 좋다.

표 4. 사전훈련 모델들의 결과

Model		S&P500			KOSPI	
MKT		0.9654			0.6176	
RL		0.8647			0.5511	
IDX		1.3621			0.6501	
CR	High	High and Low	Low	High	High and Low	Low
	0.9254	1.0392	1.4310	1.0097	1.0761	1.4988
NE	High	High and Low	Low	High	High and Low	Low
	1.2920	1.0761	1.595	1.0515	1.6083	2.0641
Model		HSI			EuroStoxx50	
MKT		0.2852			-0.3359	
RL		0.3841			0.5096	
IDX		0.5932			0.8675	
CR	High	High and Low	Low	High	High and Low	Low
	0.6949	0.6559	0.6235	0.9877	0.6129	0.3791
NE	High	High and Low	Low	High	High and Low	Low
	0.7422	0.7242	0.5422	1.2901	0.8179	0.4752



그림 8. S&P500과 그 구성 주식들 간의 관계와 측정방법에 따른 이전 학습 결과 비교

5.2 매매할 주식 개수 정하기

위에서 NumQ, NumDReg – AD, 및 NumDReg – ID 등과 같이 매번 거래할 주식 수를 결정하는 세 가지 방법을 소개했다. 각 방법은 단계적으로 개선된다. 먼저 NumQ와 NumDReg – AD 라는 두 가지 방법을 비교하여 개수 분기의 출력값이 동일한 수일 때 비교한다. 이후, 총 수익을 높이고 학습을 안정화하기 위해 4.3장에서 설명한 이전 학습을 적용한다. 이때, 5.1장의 결과를 참고하여 S&P500 및 KOSPI에 대해 가장 효과적인 NE Low 모델과 HSI 및 Eurostoxx50에 대해 가장 효과적인 NE High 모델을 적용했다. 아래에 표시된

바와 같이, 그것들은 통일된 약어, NE로 기술되어 있고 그 결과는 표 5 및 그림 9에 나타나 있다.

표 4와 5에서 볼 수 있듯이, 주식 수를 매번 결정하면서 거래를 하는 모델은 고정된 주식 거래하는 RL 모델과 비교할 때 사전 훈련 모델이 없는 경우에도 총 이익은 증가한다. NQ 및 NDA 모델은 인덱스에 의한 RL 모델과 비교하여 총 이익을 3.4에서 12.4 배로 증가시켰다. NQ 및 NDA 모델의 총 이익은 RL 모델보다 S&P500에서 4.5 배 및 3.4 배 KOSPI에서 5.8 배 및 4.6 배 높다. HSI에서 12.4 배 및 11.4 배, 마지막으로 EuroStoxx50에서 6.6배 및 5.2배 높다.

이전 학습을 적용한 후 모델인 NENQ 및 NENDA 모델에서 총 수익의 증가 수준은 모델 유형에 따라 다르지만 모든 모델은 사전 훈련을 하지 않은 NQ 및 NDA와 비교할 때 뚜렷한 증가를 보인다. S&P500에서 이전 학습은 NQ 모델에서 총 수익을 두 배, NDA 모델에서 총 수익을 1.5 배 증가시킨다. KOSPI에서 NQ 모델은 1.5 배, NDA 모델은 1.2 배의 총 수익을 증가시킨다. HSI는 NQ 모델에서 1.8 배, NDA 모델에서 1.5 배 증가시키고 마지막으로, NQ 모델에서 총 수익을 1.4 배, NDA 모델에서 총 수익을 1.2 배 증가시킨다. 이러한 결과는 5.1장의 실험 결과와 마찬가지로 이전 학습이 총 수익을 효과적으로 증가시킬 수 있음을 보여준다. 이를 통해, 개수 네트워크를 추가하면 학습의 불안정성이 증가하지만 이전 학습은 이런 네트워크를 안정화

하는데 도움을 준다는 것을 알 수 있다.

표 5에서, NQ 모델은 사전 훈련 여부와 관계없이 대부분의 경우 NDA 모델을 능가하는 것을 볼 수 있다. 이는 NDA의 학습 범위가 동시에 학습하기에 너무 크기 때문이다. 이를 해결하기 위해 학습 과정을 3 단계로 나누어 학습 범위를 줄였다. 표 5와 그림 10은 단계별 학습을 한 NENDA3 모델의 총 수익이 단계별 학습을 하지 않은 NENDA보다 높은 것을 보여준다. 구체적으로 S&P500 지수가 2배, KOSPI 지수가 1.3배, HSI 지수가 1.5배, EuroStoxx50 지수가 1.4 배 증가했다. 이러한 결과는 단계별 학습이 학습 범위를 효과적으로 제한하고 총 수익을 증가시킨다는 것을 의미한다. 또한 NENDA3의 총 수익은 NENQ의 총 수익과 비교했을 때 S&P500, KOSPI, HSI 및 EuroStoxx50 순으로 각각 약 13 %, 47 %, 26 % 및 8 %가 증가했다.

마지막으로 NENDI3 모델을 구성하여 행동에 영향을 받지 않는 매매 개수를 정한다. 출력 크기가 1로 감소함에 따라 숫자는 행동과 관계없이 시장 상황만을 고려해 정해진다. 표 5는 NENDI3 모델이 NENDA3 모델에 비해 총 수익이 S&P500, KOSPI, HSI 및 EuroStoxx50 순으로 각각 11%, 81%, 14% 및 44%의 증가한다는 것을 보여준다. 이 결과는 S&P500, KOSPI, HSI 및 EuroStoxx50의 RL 모델보다 각각 11배, 19배, 27배, 12배의 이익을 나타낸다.

표 5. NQ, NDA, NDI로 매매 개수를 정하며 거래하고 이전 학습과 단계별 학습을 적용한 결과

Model	S&P500	KOSPI	HSI	EuroStoxx50
NQ	3.8912	3.2163	4.7626	3.3882
NDA	2.9759	2.5334	4.3639	2.6322
NENQ	7.7169	3.9665	7.2330	4.0376
NENDA	4.4279	4.5590	6.1747	3.1082
NENDA3	8.6873	5.8359	9.1167	4.3487
NENDI3	9.6789	10.5704	10.4296	6.1502



그림 9. S&P500을 사용한 NQ와 NDA 모델, 그리고 이전 학습을 적용한 결과의 비교



그림 10. S&P500을 사용한 NENDA, NENDA3, NENDI3 모델의 비교

5.3 혼란스러운 시장에서의 행동 전략

혼란스러운 시장에서 매수 또는 매도 행동을 적절하게 선택하기 위해 네트워크에 행동 전략을 적용한다. 본 연구의 행동 전략은 다음과 같이 정의된다. 매수와 매도의 확률 차이가 0.2보다 작으면 (즉, 임계값이 0.2) 행동 전략에 따라 행동을 결정한다. 행동 전략을 NENDI3 모델에 적용하고 행동 전략이 동일한 임계 값을 바탕으로 BUY, HOLD 또는 SELL 인 경우 전략을 비교한다. 표 6 및 그림 11은 결과를 제시한다.

S & P500과 EuroStoxx50는 NENDI3-SELL에서 총 수익이 가장 낮지만 KOSPI 및 HSI의 경우 NENDI3-SELL이 NENDI3보다 더 나은 총 수익을 보여준다.

NENDI3-BUY는 NENDI3와 비슷한 총 수익을 나타낸다. 이 실험에서 결과는 인덱스의 움직임에 영향을 받을 수 있지만, 대부분의 경우 HOLD의 행동 전략에서 가장 높은 총 수익을 보여준다.

표 6. NENDI3에 행동 전략을 적용한 결과

Model	S&P500	KOSPI	HSI	EuroStoxx50
NENDI3	9.6789	10.5704	10.4296	6.1502
NENDI3-BUY	9.1976	7.8825	11.5862	6.9175
NENDI3-HOLD	11.4188	13.1416	9.3136	9.3237
NENDI3-SELL	4.5838	10.7684	11.2926	-9.5000




그림 11. S&P500를 사용한 행동 전략의 비교

결과적으로 HOLD를 선택하는 행동 전략은 불확실한 상황에서 잘못된 결정을 피하는데 가장 효과적이다. 이 전략은 NENDI3에 비해 S & P500, KOSPI 및 EuroStoxx50에서 각각 18 %, 24 % 및 49 %의 수익을 증가시킨다. 이것은 시장이 불투명 할 때 주식을 매수 또는 매도하는 결정을 연기하는 것이 총 이익을 증가시키는 가장 효율적인 방법임을 시사한다. HOLD 행동은 모델이 결정을 내리기 혼란스러울 때 네트워크가 안정적 이도록 훈련시킨다.

이 방법은 또한 시장에 대한 거래자의 신뢰와 거래자의 성향을 반영할 수 있다. 모델의 실제 적용 측면에서, 거래자가 주식 가격이 상승할 것이라고 확신하면 거래자는 혼란스러운 상황에서 BUY 전략을 선택할 수 있다. 반대로, 거래자가 금융 위기와 같이 주가가 하락할 것이라고 예측하면 SELL 전략을 선택할 수 있다. 마찬가지로, 거래자가 위험 회피성이 높으면 임계 값을 증가시키고 위험 회피성이 낮으면 임계 값을 감소시킬 수 있다.

6. 결론

본 연구에서 강조한 바와 같이, 강화 학습을 사용하여 주식이 거래될 때의 어려움이 발생한다. 금융 데이터는 딥러닝에 적용하기 불충분하고 매우 변동적이고 불확실한 패턴이 포함된다. 따라서 이러한 데이터를 사용하여 일반화된 의사 결정을 내리기 어렵다. 실제 의사 결정을 반영하기 위해 본 연구에서는 실제 세계를 모방하여 세 가지 새로운 방법을 제안하였고 S & P500, KOSPI, HSI 및 EuroStoxx50의 네 가지 주식으로 이를 검증하였다.

첫째, DNN regressor를 추가하여 단계적으로 학습해 거래할 주식 개수를 정한다. DQN에 DNN regressor를 추가해 개수를 정하고 단계별 교육을 통해 학습 범위를 줄인다. 이때, DNN regressor는 거래 행동에 관계없이 주식 수를 정한다. 이 방법은 총 수익을 기존 시스템에 비해 S&P500에서 4배, KOSPI에서 5배, HSI에서 12배, EuroStoxx50에서 6배 증가시킨다. 이 방법은 총 수익을 증가시킬 뿐 아니라 실제 시장에 직접적으로 적용 가능하게 구성되었다. 또한, 이 방법은 거래되는 주식의 개수가 중요한 헤지 전략에 적용될 수 있다.

둘째, 우리는 불확실한 시장에 대비하기 위해 다양한 행동 전략, 특히 임계점이 0.2이고 HOLD 행동을 선택하는 전략을 제안한다. 구매 또는 판매 결정을 연기하는 이 전략은 혼란스러운 상황을 효과적으로 제어하고 S&P500에서

18%, KOSPI에서 24%, EuroStoxx50에서 49%의 총 이익을 증가시킨다. 이 방법은 간단한 공식으로 설명될 수 있어 다른 네트워크에도 쉽게 적용 가능하고 다양한 투자자의 성향이 자동화된 알고리즘에 어떻게 반영될 수 있는지를 보여준다.

셋째, 모델을 사전 훈련하기 위해 신경망의 복원 오차에 따라 인덱스와 관계가 있는 몇 가지 구성 주식을 선택한다. 구성 주식의 수량이 적으면 인덱스와 관계가 높은 6개의 구성 주식을 선택한다. 구성 주식의 수량이 많을 때는 인덱스와 관계가 낮은 10개의 구성 주식을 선택한다. 이 접근법은 과적합을 방지하고 금융 데이터를 보다 잘 이해할 수 있도록 더 많은 정보를 제공한다. 이 방법은 거래 총 수익을 S&P500에서 2배, KOSPI에서 3배, HSI에서 2배, EuroStoxx50에서 2.5배 증가시킨다. 더욱이 이 방법을 통해 불충분한 금융 데이터의 문제를 해결할 수 있다. 이 솔루션은 금융 데이터를 어떻게 효율적으로 딥러닝에 적용할 수 있는지 보여준다. 최종적으로 기존의 강화학습 모델과 비교하면 세 가지 방법 모두 테스트 기간 동안 S&P500에서는 13배, KOSPI에서는 24배, HSI에서는 30배, EuroStoxx50에서는 18배의 총 수익이 증가한다.

이 모델은 다양하게 활용될 수 있다. 예를 들어 다중 자산 포트폴리오 최적화 모델과 같은 다른 금융 모델과 결합하여 헤지 전략을 확인할 수도 있다. 전반적으로, 이 모델은 총 수익을 향상시킬 수 있었고 운영 연구를 확장하여

금융 분야에서의 의사 결정에 관한 심층적인 분석을 위한 기초를 제공한다.

그럼에도 불구하고 우리의 연구에는 한계가 있다. 제안된 모델은 마감 거래 가격의 데이터만 분석하여 의사 결정한다. 주식 수를 예측하고 거래 행위를 보다 효과적으로 선택하기 위해서는 변동성과 같은 다른 시장 요인을 고려할 필요가 있다. 또한, 우리는 하나의 주식만을 고려한다. 따라서 이 연구는 여러 주식을 이용해 포트폴리오를 구성하는 연구로 확장될 수 있다. 우리는 앞으로의 연구를 위해 이러한 과제를 남겨 두었다.

참고문헌

- Aggarwal, S., & Aggarwal, S. (2017). Deep Investment in Financial Markets using Deep Learning Models. *International Journal of Computer Applications*, 162(2), 975–8887. Retrieved from <https://pdfs.semanticscholar.org/ca46/cd1e40f4b473641b450eb85381532eab4294.pdf>
- Almahdi, S., & Yang, S. Y. (2017). An adaptive portfolio trading system: A risk-return portfolio optimization using recurrent reinforcement learning with expected maximum drawdown. *Expert Systems with Applications*, 87, 267–279. <https://doi.org/10.1016/j.eswa.2017.06.023>
- Ang, K. K., & Quek, C. (2006). Stock Trading Using RSPOP : A Novel Rough Set-Based Neuro-Fuzzy Approach. *IEEE Transactions on Neural Networks*, 17(5), 1301–1315. <https://doi.org/10.1109/TNN.2006.875996>
- Aquino, C. F., Chamhum Salomão, L. C., & Azevedo, A. M. (2016). High-efficiency phenotyping for vitamin A in banana using artificial neural networks and colorimetric data, 75(3), 268–274. <https://doi.org/10.1590/1678-4499.467>
- Bellman, R. (1957). A Markovian decision process. *Journal Of Mathematics And Mechanics*. <https://doi.org/10.1007/BF02935461>
- Bergstra, J., & Yoshua Bengio, U. (2012). Random Search for Hyper-Parameter Optimization. *Journal of Machine Learning Research*, 13, 281–305. <https://doi.org/10.1162/153244303322533223>
- Black, F., & Scholes, M. (1973). The Pricing of Options and Corporate Liabilities. *Journal of Political Economy*, 81(3), 637–654. <https://doi.org/10.1086/260062>
- Brock, W., Lakonishok, J., & LeBaron, B. (1992). Simple Technical Trading Rules and the Stochastic Properties of Stock Returns. *The Journal of Finance*, 47(5), 1731–1764. <https://doi.org/10.1111/j.1540-6261.1992.tb04681.x>

- Brownlees, C. T., Cipollini, F., & Gallo, G. M. (2011). Intra-daily volume modeling and prediction for algorithmic trading. *Journal of Financial Econometrics*, 9(3), 489–518. <https://doi.org/10.1093/jfinec/nbq024>
- Campbell, J. Y. ., Grossman, S. J. ., & Wang, J. (2011). Trading Volume and Serial Correlation in Stock Returns. *The MIT Press*, 108(4), 905–939. <https://doi.org/10.2307/2118454>
- Chaboud, A. P., Chiquoine, B., Hjalmarsson, E., & Vega, C. (2009). Rise of the machines: Algorithmic trading in the foreign exchange market. *The Journal of Finance*, 69(5), 2045–2084. <https://doi.org/10.1111/jofi.12186>
- Chavarnakul, T., & Enke, D. (2008). Intelligent technical analysis based equivolume charting for stock trading using neural networks. *Expert Systems with Applications*, 34(2), 1004–1017. <https://doi.org/10.1016/j.eswa.2006.10.028>
- Chen, G. meng, Firth, M., & Rui, O. M. (2001). The dynamic relation between stock returns, trading volume, and volatility. *Financial Review*, 36(3), 153–174. <https://doi.org/10.1111/j.1540-6288.2001.tb00024.x>
- DeLong, J. B., & Magin, K. (2006). A Short Note on the Size of the Dot-Com Bubble. *NBER Working Paper No. 12011*, 1–14. <https://doi.org/10.3386/w12011>
- Dempster, M. A. H., & Leemans, V. (2006). An automated FX trading system using adaptive reinforcement learning. *Expert Systems with Applications*, 30(3), 543–552. <https://doi.org/10.1016/j.eswa.2005.10.012>
- Dempster, M. A. H., Payne, T. W., Romahi, Y., & Thompson, G. W. P. (2001). Computational learning techniques for intraday FX trading using popular technical indicators. *IEEE Transactions on Neural Networks*, 12(4), 744–754. <https://doi.org/10.1109/72.935088>
- Deng, Y., Bao, F., Kong, Y., Ren, Z., & Dai, Q. (2017). Deep Direct Reinforcement Learning for Financial Signal Representation and Trading. *IEEE Transactions on Neural Networks and Learning Systems*, 28(3), 653–664.

<https://doi.org/10.1109/TNNLS.2016.2522401>

- Domowitz, I., & Yegerman, H. (2006). The Cost of Algorithmic Trading. *The Journal of Trading*, 1(1), 33–42. <https://doi.org/10.3905/jot.2006.609174>
- Duchi, J., & Singer, Y. (2009). Efficient Online and Batch Learning Using Forward Backward Splitting. *Journal of Machine Learning Research*, 10, 2899–2934. <https://doi.org/10.1561/24000000003>
- Dymova, L., Sevastianov, P., & Bartosiewicz, P. (2010). A new approach to the rule-base evidential reasoning: Stock trading expert system application. *Expert Systems with Applications*, 37(8), 5564–5576. <https://doi.org/10.1016/j.eswa.2010.02.056>
- Fama, E. F. (1995). Random Walks in Stock Market Prices. *Financial Analysts Journal*, 51(1), 75–80. <https://doi.org/10.2469/faj.v51.n1.1861>
- Flood, M. D. (2012). A brief history of financial risk and information. *Handbook of Financial Data and Risk Information*, Volume 1, M. Brose, M. Flood, D. Krishna, and W. Nichols, Eds., Cambridge University Press, 2014, 1–32. Retrieved from <http://dx.doi.org/10.2139/ssrn.2150987>
- Ghosh, S., Laksana, E., Morency, L.-P., & Scherer, S. (2016). Representation Learning for Speech Emotion Recognition, (September), 3603–3607. <https://doi.org/10.21437/Interspeech.2016-692>
- Gorse, D., & Street, G. (2011). Application of stochastic recurrent reinforcement learning to index trading. *ESANN 2011 Proceedings, European Symposium on Artificial Neural Networks, Computational Intelligence and Machine Learning*, 27–29. Retrieved from <http://discovery.ucl.ac.uk/id/eprint/1339314>
- Heaton, J. B., Polson, N. G., & Witte, J. H. (2017). Deep learning for finance: deep portfolios. *Applied Stochastic Models in Business and Industry*, 33(1), 3–12. <https://doi.org/10.1002/asmb.2209>
- Hendershott, T., Jones, C. M., & Menkveld, A. J. (2011). Does algorithmic trading improve liquidity? *Journal of Finance*, 66(1), 1–33.

<https://doi.org/10.1111/j.1540-6261.2010.01624.x>

Hendershott, T., & Riordan, R. (2011). Algorithmic Trading and Information.

Working Paper, University of California, Berkeley.

<https://doi.org/10.2139/ssrn.1472050>

Hess, A., Epps, T. W., & Bamber, L. (2013). The Relation Between Price Changes and Trading Volume : A Survey Author (s): Jonathan M . Karpoff

Source : The Journal of Financial and Quantitative Analysis , Vol . 22, No. 1 (Mar., 1987), pp . Published by Cambridge University Press on behalf o, 22(1), 109–126.

Hu, Y., Liu, K., Zhang, X., Su, L., Ngai, E. W. T., & Liu, M. (2015). Application of evolutionary computation for rule discovery in stock algorithmic trading: A literature review. *Applied Soft Computing*, 36, 534–551.

<https://doi.org/10.1016/j.asoc.2015.07.008>

Ioffe, S., & Szegedy, C. (2015). Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift.

<https://doi.org/10.1007/s13398-014-0173-7.2>

Jiang, Z., Xu, D., & Liang, J. (2017). A Deep Reinforcement Learning Framework for the Financial Portfolio Management Problem. *ArXiv*, 1706.10059, 1–31. Retrieved from <http://arxiv.org/abs/1706.10059>

Kaelbling, L., Littman, M., & Moore, A. (1996). Reinforcement Learning: A Survey. *Journal of Artificial Intelligence Research*, 4, 237–285.

<https://doi.org/10.1613/jair.301>

Kindleberger, C. P., & Aliber, R. Z. (2005). *Manias, Panics and Crashes*. John Wiley 3d. Ed. <https://doi.org/10.1057/9780230628045>

Kingma, D. P., & Ba, J. (2014). Adam: A Method for Stochastic Optimization. *ArXiv*, 1412.6980, 1–15.

<https://doi.org/http://doi.acm.org.ezproxy.lib.ucf.edu/10.1145/1830483.1830503>

Kuo, R. J., Chen, C. H., & Hwang, Y. C. (2001). An intelligent stock trading

decision support system through integration of genetic algorithm based fuzzy neural network and artificial neural network. *Fuzzy Sets and Systems*, 118(1), 21–45. [https://doi.org/https://doi.org/10.1016/S0165-0114\(98\)00399-6](https://doi.org/https://doi.org/10.1016/S0165-0114(98)00399-6)

Levich, R. M., & Thomas, L. R. (1993). THE SIGNIFICANCE OF TECHNICAL TRADING-RULE PROFITS. *Journal of International Money and Finance*, 12(5), 451–474. [https://doi.org/https://doi.org/10.1016/0261-5606\(93\)90034-9](https://doi.org/https://doi.org/10.1016/0261-5606(93)90034-9)

Lin, X., Yang, Z., & Song, Y. (2011). Intelligent stock trading system based on improved technical analysis and Echo State Network. *Expert Systems with Applications*, 38(9), 11347–11354. <https://doi.org/10.1016/j.eswa.2011.03.001>

Lu, Z., Zhu, Y., Pan, S. J., Xiang, E. W., Wang, Y., & Yang, Q. (2014). Source Free Transfer Learning for Text Classification. *AAAI Conference on Artificial Intelligence*, 122–128. Retrieved from <https://www.aaai.org/ocs/index.php/AAAI/AAAI14/paper/view/8361>

Mastinšek, M. (2006). Discrete-time delta hedging and the Black-Scholes model with transaction costs. *Mathematical Methods of Operations Research*, 64(2), 227–236. <https://doi.org/10.1007/s00186-006-0086-0>

Mnih, V., Kavukcuoglu, K., Silver, D., Rusu, A., Veness, J., Bellemare, M., Graves, A., Riedmiller, M., Fidjeland, A., Ostrovski, G., Petersen, S., Beattie, C., Sadik, A., Antonoglou, I., King, H., Kumaran, D., Wierstra, D., Legg, S., & Hassabis, D. (2015). Human-level control through deep reinforcement learning. *Nature*, 518, 529–533. <https://doi.org/10.1038/nature14236>

Mnih, V., Kavukcuoglu, K., Silver, D., Graves, A., Antonoglou, I., Wierstra, D., & Riedmiller, M. (2013). Playing Atari with Deep Reinforcement Learning. *ArXiv*, 1312.5602, 1–9. <https://doi.org/10.1038/nature14236>

Moody, J., & Saffell, M. (2001). Learning to trade via direct reinforcement. *IEEE Transactions on Neural Networks*, 12(4), 875–889.

<https://doi.org/10.1109/72.935097>

- Nair, V., & Hinton, G. E. (2010). Rectified Linear Units Improve Restricted Boltzmann Machines. *Proceedings of the 27th International Conference on Machine Learning*, (3), 807–814. <https://doi.org/10.1.1.165.6419>
- O, J., Lee, J., Lee, J. W., & Zhang, B. T. (2006). Adaptive stock trading with dynamic asset allocation using reinforcement learning. *Information Sciences*, 176(15), 2121–2147. <https://doi.org/10.1016/j.ins.2005.10.009>
- Oh, K. J., & Kim, K. J. (2002). Analyzing stock market tick data using piecewise nonlinear model. *Expert Systems with Applications*, 22(3), 249–255. [https://doi.org/10.1016/S0957-4174\(01\)00058-6](https://doi.org/10.1016/S0957-4174(01)00058-6)
- Pan, S. Yang, Q. (2010). a Survey on Transfer Learning. *IEEE Transactions on Knowledge and Data Engineering*, 22(10), 1345–1359. <https://doi.org/10.1109/TKDE.2009.191>
- Pendharkar, P. C., & Cusatis, P. (2018). Trading financial indices with reinforcement learning agents. *Expert Systems with Applications*, 103, 1–13. <https://doi.org/10.1016/j.eswa.2018.02.032>
- Press, C. (2016). Filter Rules and Stock-Market Trading Author (s): Eugene F. Fama and Marshall E Blume Source: The Journal of Business, Vol 39 No.1 , Part 2 : Supplement on Security Prices Published by : The University of Chicago Press Stable URL : <http://www>, 39(1), 226–241.
- Scholtus, M., Van Dijk, D., & Frijns, B. (2014). Speed, algorithmic trading, and market quality around macroeconomic news announcements. *Journal of Banking and Finance*, 38(1), 89–105. <https://doi.org/10.1016/j.jbankfin.2013.09.016>
- Shalev-Shwartz, S., Singer, Y., & Ng, A. Y. (2004). Online and batch learning of pseudo-metrics. *Twenty-First International Conference on Machine Learning - ICML '04*, 94. <https://doi.org/10.1145/1015330.1015376>
- Sudo, a, Sato, a, & Hasegawa, O. (2009). Associative Memory for Online Learning in Noisy Environments Using Self-Organizing Incremental Neural

- Network. Neural Networks, IEEE Transactions On, 20(6), 964–972.
<https://doi.org/10.1109/TNN.2009.2014374>
- Sutton, R. S., & Barto, A. G. (1998). Reinforcement Learning: An Introduction. IEEE Transactions on Neural Networks, 9(5), 1054–1054.
<https://doi.org/10.1109/TNN.1998.712192>
- Taghavifar, H., Taghavifar, H., Mardani, A., & Mohebbi, A. (2014). Modeling the impact of in-cylinder combustion parameters of di engines on soot and NOx emissions at rated EGR levels using ANN approach. Energy Conversion and Management, 87, 1–9.
<https://doi.org/10.1016/j.enconman.2014.07.005>
- Tan, Z., Quek, C., & Cheng, P. Y. K. (2011). Stock trading with cycles: A financial application of ANFIS and reinforcement learning. Expert Systems with Applications, 38(5), 4741–4755.
<https://doi.org/10.1016/j.eswa.2010.09.001>
- Vijayakumar, S., D'souza, A., & Schaal, S. (2005). Incremental Online Learning in High Dimensions. Neural Computation, 17, 2602–2634.
<https://doi.org/10.1162/089976605774320557>
- Wang, Y., Wang, D., Zhang, S., Feng, Y., Li, S., & Zhou, Q. (2017). Deep Q-trading. Cslt.Riit.Tsinghua.Edu.Cn, 1–9. Retrieved from <http://cslt.riit.tsinghua.edu.cn/mediawiki/images/5/5f/Dtq.pdf>
- Watkins, C. J. C. H., & Dayan, P. (1992). Q-learning. Machine Learning, 8(3–4), 279–292. <https://doi.org/10.1007/BF00992698>
- Wu, D., Lance, B. J., & Parsons, T. D. (2013). Collaborative Filtering for Brain-Computer Interaction Using Transfer Learning and Active Class Selection. PLoS ONE, 8(2). <https://doi.org/10.1371/journal.pone.0056624>
- Yadav, Y. (2015). How Algorithmic Trading Undermines Efficiency in Capital Markets. VAND. L. REV.
- Yang, S., Paddrik, M., Hayes, R., Todd, A., Kirilenko, A., Beling, P., & Scherer, W. (2012). Behavior based learning in identifying High Frequency Trading

strategies. 2012 IEEE Conference on Computational Intelligence for Financial Engineering & Economics (CIFEr), 1–8.

<https://doi.org/10.1109/CIFEr.2012.6327783>



Abstract

We study trading systems using reinforcement learning with three newly proposed methods to maximize total profits and reflect real financial market situations while overcoming the limitations of financial data. First, we propose a trading system that can predict the number of shares to trade. Specifically, we design an automated system that predicts the number of shares by adding a deep neural network (DNN) regressor to a deep Q-network, thereby combining reinforcement learning and a DNN. Second, we study various action strategies that use Q-values to analyze which action strategies are beneficial for profits in a confused market. Finally, we propose transfer learning approaches to prevent overfitting from insufficient financial data. We use four different stock indices—the S&P500, KOSPI, HSI, and EuroStoxx50—to experimentally verify our proposed methods and then conduct extensive research. The proposed automated trading system, which enables us to predict the number of shares with the DNN regressor, increases total profits by four times in S&P500, five times in KOSPI, 12 times in HSI, and six times in EuroStoxx50 compared with the fixed-number trading system. When the market situation is confused, delaying the decision to buy or sell increases total profits by 18% in S&P500, 24% in KOSPI, and 49% in EuroStoxx50. Further, transfer learning increases total profits by twofold in S&P500, 3 times in KOSPI, twofold in HSI, and 2.5 times in EuroStoxx50. The trading system with all three proposed methods increases total profits by 13 times in S&P500, 24 times in KOSPI, 30 times in HSI, and 18 times in EuroStoxx50, outperforming the market and the reinforcement learning model.